

SUELLEN SILVA DE ALMEIDA

Orientador: David Menotti

**ANÁLISE DE DESCRITORES PARA CARACTERIZAÇÃO
AUTOMÁTICA DOS AGENTES CAUSADORES DE LESÕES
EM FOLÍOLOS DE CULTIVARES DO BRASIL**

Ouro Preto
Novembro de 2011

UNIVERSIDADE FEDERAL DE OURO PRETO
INSTITUTO DE CIÊNCIAS EXATAS
BACHARELADO EM CIÊNCIA DA COMPUTAÇÃO

**ANÁLISE DE DESCRITORES PARA CARACTERIZAÇÃO
AUTOMÁTICA DOS AGENTES CAUSADORES DE LESÕES
EM FOLÍOLOS DE CULTIVARES DO BRASIL**

Monografia apresentada ao Curso de Bacharelado em Ciência da Computação da Universidade Federal de Ouro Preto como requisito parcial para a obtenção do grau de Bacharel em Ciência da Computação.

SUELLEN SILVA DE ALMEIDA

Ouro Preto
Novembro de 2011



UNIVERSIDADE FEDERAL DE OURO PRETO

FOLHA DE APROVAÇÃO

Análise de Descritores para Caracterização Automática dos Agentes
Causadores de Lesões em Folíolos de Cultivares do Brasil

SUELLEN SILVA DE ALMEIDA

Monografia defendida e aprovada pela banca examinadora constituída por:

Dr. DAVID MENOTTI – Orientador
Universidade Federal de Ouro Preto

Dr. GUILLERMO CÁMARA-CHÁVEZ
Universidade Federal de Ouro Preto

Dr. LUIZ HENRIQUE CAMPOS MERSCHMANN
Universidade Federal de Ouro Preto

Me. ANDERSON ALMEIDA FERREIRA
Universidade Federal de Ouro Preto

Ouro Preto, Novembro de 2011

Resumo

Grande parte das dificuldades de manejo em culturas de soja está relacionada à detecção do inseto/praga nocivo aos cultivares, visto que essas culturas estão sujeitas a ataques de uma ampla gama de pragas. Com a identificação dos agentes mais comuns que causam danos aos folíolos, é possível obter maior conhecimento sobre estratégias adequadas de controle. O trabalho proposto apresenta um método automático para caracterização dos principais agentes causadores de lesões em folíolos de soja, *i.e.*, coleópteros e lagartas. As imagens dos folíolos de soja adquiridas são pré-processadas e os danos extraídos. A partir dos contornos e áreas dos danos, características são extraídas por meio de vários tipos de descritores. Dois deles modelam o contorno como uma rede complexa e extraem as características baseados na conectividade e no *joint degree* de sua rede. Os outros são os descritores de forma de Fourier, Wavelet e de Zernike. Essas características são utilizadas para treinar o algoritmo classificador *Support Vector Machines* (SVM). Nos experimentos, os diferentes descritores e os limiares (*thresholds*) que modelam a rede complexa são analisados e o método proposto utilizando os descritores *joint degree* apresentou precisão maior que 90% para classificação dos agentes danificadores. O método com os descritores de Fourier apresentou precisão média de 90%, além de necessitar de menor quantidade de parâmetros que os descritores de *joint degree*. Os outros descritores não apresentaram resultados satisfatórios (iguais ou maiores que 90%) com o algoritmo de classificação utilizado.

Abstract

Many of the difficulties in managing soybean tillage are related to the identification of insect/pests harmful to the plant, since tillage can be attacked by a wide range of such agents. By identifying the most common agents that cause damages to the leaflets, we can obtain more knowledge about appropriate strategies of control. The proposed work presents an automatic method for classification of the main agents that cause damages to soybean leaflets, *i.e.*, beetles and caterpillars. Acquired images are preprocessed and the damages are taken. From the contours and area of the damages, features are extracted using various descriptors. Two of them model each contour as a complex network and extract the features based on the connectivity and the joint degree of this network. The others are the shape descriptors of Fourier, Wavelet and of Zernike. These features are then used to train a Support Vector Machines (SVM) classifier algorithm. In the experiments, we analyze the different descriptors and thresholds which model the network and the proposed method with joint degree descriptors reports accuracy greater than 90% for damaging agent classification. The method with descriptors of Fourier presented average accuracy of 90%, and require less number of parameters that the descriptors of joint degree. The others descriptors did not show satisfactory results (equal or greater than 90%) with the classification algorithm used.

Dedico este trabalho a Deus, aos meus pais, e ao Thiago.

Agradecimentos

Passaram quatro anos e ainda me lembro como se fosse ontem da aprovação no vestibular e da decisão de mudar para Ouro Preto. Foram grandes mudanças em minha vida e algumas pessoas foram essenciais. Essas pessoas me ajudaram a superar os desafios, a crescer como pessoa, foram companheiras e sempre torceram por mim, a elas vão os meus agradecimentos.

Antes de qualquer coisa, agradeço a Deus por estar sempre presente na minha vida. Agradeço pelo Seu infinito e perfeito amor, pela paciência e cuidado. Por me entender, me ajudar, me dar força, enfim, por cuidar de cada detalhe de minha vida da melhor forma existente.

Agradeço também aos meus pais, as pessoas que mais me incentivaram, os melhores exemplos de vida que posso ter. Sempre me mostraram que o coração e a razão podem caminhar juntos, que a verdadeira sabedoria vem de Deus. Nunca conseguirei retribuir tanto amor, tanta dedicação, só tenho a agradecer por tudo que sempre fizeram por mim. Sem eles eu não teria conseguido. A eles todo o meu amor.

À minha irmã pelo carinho e apoio. Agradeço também às minhas amigas Amanda, Bárbara, Duda, Lê, Natasha e Aninha, pela amizade verdadeira, por me ouvirem, torcerem por mim e por estarem sempre presentes mesmo longe, não poderia desejar amigas melhores. Agradeço também ao Lucinho pelo carinho, paciência, apoio, dedicação e companheirismo. O meu amor por vocês é infinito.

Aos amigos e colegas de curso, especialmente o Júnior pelo companheirismo e disposição para me ajudar e me ouvir em todos os momentos. Aos professores do DECOM, principalmente ao David Menotti, o melhor orientador que eu poderia ter escolhido, pela dedicação, preocupação, esforço, principalmente por acreditar em mim e por fazer com que eu acredite mais em mim.

Aos colegas de Alvo e principalmente a Cecília, Bela, Larissa, Bárbara e Luma que me acolheram com tanto amor e carinho, me ouviram, me ajudaram e sempre tentaram me entender mesmo em momentos diferentes de vida.

Agradeço também, com todo o meu coração, ao Thiago. Só depois de perdê-lo percebi quantas lições de vida ele deu, quanto eu poderia ter aprendido e crescido mais perto dele. Esse trabalho se tornou ainda mais importante pra mim por causa dele. Ficaram as melhores lembranças e a saudade.

Enfim, agradeço a todos que contribuíram para essa conquista.

Sumário

1	Introdução	1
2	Trabalhos Relacionados	5
3	Método Proposto	8
3.1	Pré-Processamento das Imagens	9
3.2	Extração de Características	10
3.2.1	Descritores baseados em redes complexas	10
3.2.2	Descritores baseados no contorno	14
3.2.3	Descritor baseados na área	20
3.3	Classificação	21
3.3.1	<i>Support Vector Machines</i> - SVM	21
3.4	Considerações Finais	24
4	Sistema Web	25
5	Experimentos	28
5.1	Base de Dados	28
5.2	Treino e Teste do SVM	28
5.3	Resultados	30
5.3.1	Resultados utilizando os descritores baseados em redes complexas	30
5.3.2	Resultados utilizando os descritores de Fourier	33
5.3.3	Resultados utilizando os descritores <i>Wavelet</i>	34
5.3.4	Resultados utilizando os descritores de Zernike	35
5.4	Grau de “Robustez” das Características	35
5.5	Análise Geral dos Resultados	36
5.6	Exemplo Ilustrativo	38
6	Conclusões e Trabalhos Futuros	40
	Referências Bibliográficas	42

Lista de Figuras

1.1	Recortes em folíolos de soja: (a) Dano atribuído a um coleóptero e imagem ilustrativa do coleóptero; (b) Dano atribuído a uma lagarta e imagem ilustrativa da lagarta.	2
1.2	Exemplo ilustrativo: (a) Danos causados por coleópteros; (b) Danos causados por lagartas.	2
3.1	Etapas de desenvolvimento do método proposto.	8
3.2	Exemplo ilustrativo: (a) Imagem de entrada com os danos rotulados; (b) Processo de filtragem Nazaré-Jr et al. (2010) ; (c) Extração do contorno do dano.	10
3.3	Exemplo dos primeiros passos do algoritmo seguidor de fronteira.	15
3.4	Exemplo ilustrativo: (a) Dano original; (b) Dano no domínio da frequência; (c) 50 primeiros coeficientes de Fourier do dano; (d) Dano reconstruído a partir dos coeficientes de Fourier apresentados (c).	15
3.5	Exemplo ilustrativo: (a) Contorno de um dano com 280 pontos; (b) a (h) Contornos reconstruídos usando 50, 40, 30, 20, 10, 5 e 2 descritores.	17
3.6	Exemplo da Transformada <i>Wavelet</i> decompondo um sinal S em 3 níveis. A e D representam os sinais de aproximação e detalhe, respectivamente.	18
3.7	(a) a (f) Contornos reconstruídos usando 128, 66, 35, 20, 12 e 8 descritores <i>wavelet</i>	19
3.8	Exemplo SVM - Mapeamento do espaço de características	22
3.9	Exemplo SVM - Maximização da margem: (a) Separação perfeita, mas não ótima; (b) Separação ótima.	22
4.1	<i>Print Screen</i> do Sistema Web para avaliação dos danos dos folíolos de soja	26
5.1	Exemplo das amostras de folíolos de soja da nossa base de dados.	28
5.2	Distribuição estatística dos agentes causadores de danos (coleópteros e lagartas) para todas as folhas da base de dados utilizada. O eixo y representa a quantidade de danos das folhas e o eixo x representa as folhas da base de dados, cada folha é relacionada a uma cor.	29
5.3	Escolha dos melhores valores para C e γ	30

5.4	Exemplo ilustrativo da classificação do SVM para os cinco descritores utilizados. Os danos coloridos de vermelho são danos de lagartas classificados corretamente; os danos em azul são os de coleópteros classificados corretamente; os danos em amarelo são de lagarta que foram classificados como de coleópteros; os danos em ciano são de coleópteros classificados como de lagarta.	39
-----	---	----

Lista de Tabelas

5.1	Dados estatísticos sobre a base de amostras	29
5.2	Acurácia para a classificação dos agentes causadores de danos e as sensitividades para as classes lagarto/ <i>caterpillar</i> (SenC) e coleóptero/ <i>beetle</i> (SenB) utilizando os descritores de Conectividade para vários limiares T_0 e T_Q . Os valores entre parenteses significam o desvio padrão para o esquema de validação- cruzada <i>leave-one-out</i>	31
5.3	Acurácia para a classificação dos agentes causadores de danos e as sensitividades para as classes lagarto/ <i>caterpillar</i> (SenC) e coleóptero/ <i>beetle</i> (SenB) utilizando os 5 descritores de Conectividade combinados e separados. Os valores entre parenteses significam o desvio padrão para o esquema de validação- cruzada <i>leave-one-out</i>	32
5.4	Acurácia para a classificação dos agentes causadores de danos e as sensitividades para as classes Lagarto/ <i>Caterpillar</i> (SenC) e coleóptero/ <i>beetle</i> (SenB) utilizando descritores <i>Joint Degree</i> (Energia, Entropia e <i>Joint Degree</i> médio). Os valores entre parenteses significam o desvio padrão para o esquema de validação- cruzada <i>leave-one-out</i>	32
5.5	Acurácia para a classificação dos agentes causadores de danos e as sensitividades para as classes Lagarto/ <i>Caterpillar</i> (SenC) e coleóptero/ <i>beetle</i> (SenB) utilizando descritores 5 <i>Joint Degree</i> separados e combinados de dois a dois. Os valores entre parenteses significam o desvio padrão para o esquema de validação- cruzada <i>leave-one-out</i>	33
5.6	Acurácia para a classificação dos agentes causadores de danos e as sensitividades para as classes lagarta/ <i>caterpillar</i> (SenC) e coleóptero/ <i>beetle</i> (SenB) utilizando os descritores de Fourier. Foram utilizados os 2, 3, 5, 10, 15, 20, 25, 30, 40 e 50 primeiros descritores. Os valores entre parenteses significam o desvio padrão para o esquema de validação-cruzada <i>leave-one-out</i>	33
5.7	Acurácia para a classificação dos agentes causadores de danos e as sensitividades para as classes lagarta/ <i>caterpillar</i> (SenC) e coleóptero/ <i>beetle</i> (SenB) utilizando os descritores <i>Wavelet</i> com as funções de base Haar, Db2 e Db3. Os valores entre parenteses significam o desvio padrão para o esquema de validação- cruzada <i>leave-one-out</i>	34

5.8	Acurácia para a classificação dos agentes causadores de danos e as sensitividades para as classes lagarto/ <i>caterpillar</i> (SenC) e coleóptero/ <i>beetle</i> (SenB) utilizando os descritores de Zernike de ordem variando de 1 a 18. Os valores entre parenteses significam o desvio padrão para o esquema de validação- cruzada <i>leave-one-out</i> . . .	35
5.9	Teste-t Emparelhado: Grau de “Robustez” das Características em Porcentagem. . .	37
5.10	Resumo dos resultados obtidos para os diferentes descritores	38

Capítulo 1

Introdução

A soja é uma das mais importantes culturas agrícolas em todo o mundo e principalmente no Brasil, que é o segundo maior produtor. Em nosso país, a cultura da soja apresenta sensíveis avanços tecnológicos que propiciam incremento na produtividade de grãos nas diversas regiões produtoras do país. Neste contexto, os insetos/pragas constituem um dos principais problemas enfrentados pelos produtores de soja com vista a alcançarem alta produtividade de grãos (Picanço e Guedes, 1999).

O controle dessas pragas das culturas de soja pode consistir em um sistema de tomada de decisões baseado nos diferentes tipos de insetos/pragas em cultivares, bem como na frequência em que ocorre cada um destes agentes. De acordo com de Moura et al. (2003), na maioria dos casos, a escolha da medida de controle ocorre de maneira não planejada, geralmente pelo uso excessivo de produtos químicos, medida que traz prejuízos, resultando na poluição ao meio ambiente e intoxicação ao homem. A identificação das ocorrências mais comuns (*e.g.*, coleópteros, lagartas, *etc.*) em conjunto com a determinação da frequência com que cada agente ocorre em folíolos, favorece a escolha de uma estratégia eficiente de controle.

Segundo Styrsky et al. (2005), o método mais usado para identificação e frequência de amostragem dos agentes danificadores é baseado no “pano de batida”, técnica realizada por humanos da seguinte forma. Um pano é colocado entre duas fileiras paralelas de cultivares de soja. As plantas são inclinadas e balançadas de modo que os insetos caiam sobre o pano. Para efeito de amostragem, estes insetos são identificados e contabilizados a fim de estimar a razão em que ocorre cada um destes agentes. Esta técnica apresenta uma baixa taxa de amostragem, é dispendiosa em relação ao tempo e apresenta um alto grau de imprecisão.

De acordo com especialistas em fitotecnia da Universidade Federal de Viçosa (Souza et al., 2010), é possível distinguir as duas classes principais de agentes causadores de danos (*i.e.*, coleópteros, lagartas como ilustram as imagens da Figura 1.1), utilizando a forma (contorno, área, *etc.*) de cada dano causado nos folíolos.

Todavia, a tarefa de distinguir as duas principais classes é complexa tanto para seres humanos quanto para computadores, pois não há um padrão igual para todos os danos. De fato,




Figura 1.1: Recortes em folíolos de soja: (a) Dano atribuído a um coleóptero e imagem ilustrativa do coleóptero; (b) Dano atribuído a uma lagarta e imagem ilustrativa da lagarta.

o contorno e área dos danos causados por coleópteros seguem uma tendência de serem mais regulares e circulares, diferentemente dos danos das lagartas que são totalmente irregulares. No entanto, os danos de ambas as classes sofrem grandes variações, o que dificulta colocar os danos de determinada classe em um padrão específico e constante. Sempre ocorrem variações. Essas variações podem ser visualizadas nos danos representados na Figura 1.2.




Figura 1.2: Exemplo ilustrativo: (a) Danos causados por coleópteros; (b) Danos causados por lagartas.

Na literatura atual, existem técnicas de classificação automática relacionadas a cultivares e também às suas patologias (apresentados no Capítulo 2), porém não se encontram métodos acerca da caracterização das pragas que agem sobre as culturas. Além disso, a maioria desses métodos que classificam formas procura por um padrão fixo para todas as amostras. Pode ocorrer alguma variação de uma amostra para outra, mas são detalhes mínimos. No nosso caso essas variações são grandes pois os danos são criados por insetos do meio ambiente que não

possuem um comportamento bem definido, o que gera mais complexidade para a classificação.

Sistemas de visão computacional mostraram resultados superiores aos obtidos pelos seres humanos para estimar a área dos danos dos folíolos em imagens digitais (Nazaré-Jr et al., 2010). Acredita-se que esses sistemas podem ser ainda melhores, com maior acurácia, e com a obtenção de resultados mais rápidos que humanos quando aplicado à tarefa de classificação dos agentes danificadores dos folíolos de soja, visto que essa tarefa envolve uma análise visual repetitiva e detalhada.

Para classificar os agentes danificadores utilizando a forma do dano, é necessário utilizar técnicas da área de Reconhecimento de Padrões. De acordo com Backes et al. (2009), existem duas abordagens principais para representação de formas: (1) abordagem baseada na região, que usa momentos (Zhenjiang, 2000) para descrever as formas; e (2) abordagem baseada no contorno, que usa técnicas como descritores de Fourier (Briggs e Henson (1995), Zahn e Roskies (1972)) e descritores *Wavelet* (Osowski e Nghia (2002), Mallat (1989)). Uma nova abordagem para representação de formas é introduzida em Backes et al. (2009), que realiza a análise do contorno da forma utilizando redes complexas.

Este trabalho apresenta um método para caracterização automática desses agentes usando imagens digitais. Este método, proposto inicialmente por Souza et al. (2011b) (utilizando descritores baseados em redes complexas), foi incrementado com outros descritores de características (Fourier (Osowski e Nghia, 2002), *Wavelet* (Osowski e Nghia, 2002) e Zernike (Zhenjiang, 2000)) para efeito de comparação e escolha do descritor que gera a melhor representação das classes realizada pelo algoritmo de aprendizado de máquina *Support Vector Machines* (SVM) (Cortes e Vapnik, 1995). Então, de fato, este trabalho apresenta e analisa esses vários descritores de características, para indicar e escolher qual deles deve fazer parte do método de caracterização automática.

Além disso, este método complementa outro método proposto em Nazaré-Jr et al. (2010) para detecção automática e quantificação da área foliar danificada da soja. Para classificação dos folíolos a respeito dos agentes danificadores, é possível classificar o folíolo apenas por lagartas, principalmente por lagartas, principalmente por coleópteros, apenas coleópteros e ambos, onde o termo “apenas” é empregado se mais do que 90% dos danos são causados por apenas um dos agentes; “ambos” é utilizado quando metade dos danos (*e.g.*, $50\% \pm 10\%$) são causados por ambos agentes, e “principalmente” caso contrário. Nesse caso, a área (Nazaré-Jr et al., 2010) de cada dano é levada em consideração para computar o dano total de cada agente. Então, a combinação desses métodos torna possível a escolha de uma estratégia de controle eficiente, a qual irá reduzir as perdas financeiras e a degradação do ambiente, causadas pelo uso excessivo de defensivos agrícolas.

O objetivo desse trabalho é analisar diferentes descritores a fim de escolher o melhor para ser utilizado no método de classificação automática dos agentes danificadores de folíolos de soja também proposto nesse trabalho. Ser o melhor descritor significa, em nosso caso, o

descriptor que gera a melhor representação das classes e assim obtém os melhores resultados de classificação com o algoritmo de aprendizado de máquina *Support Vector Machines* (SVM).

Esse trabalho apresenta contribuições tanto para esferas agrícola, econômica e ambiental. A identificação correta do agente causadores do dano e as subsequentes ações tomadas a partir dela poderão proporcionar tanto uma economia de recursos financeiros (por exemplo, na compra de agrotóxicos) quanto ambientais. A utilização do uso de agrotóxicos apenas em situações de comprovada necessidade evita os danos que esses podem causar ao ambiente. A ferramenta gerada com esse trabalho auxiliará o diagnóstico do especialista, sem fadiga nem exaustão, mantendo sempre a mesma precisão.

A organização dos próximos capítulos é explicada a seguir. O Capítulo 2 relata os trabalhos relacionados ao nosso trabalho. No Capítulo 3, o método proposto é apresentado com detalhes. O sistema web implementado para rotulação manual das amostras realizada por especialista é descrito no Capítulo 4. No Capítulo 5, os experimentos utilizando uma base de dados com 178 imagens de folíolos de soja e 1780 amostras dos danos desses folíolos são apresentados a fim de validar e reportar a acurácia do método proposto. Finalmente, o Capítulo 6 descreve as conclusões e trabalhos futuros.

Capítulo 2

Trabalhos Relacionados

Na literatura atual, existem técnicas de classificação automática relacionadas a cultivares e também às suas patologias, porém não se encontram métodos acerca da caracterização das pragas que agem sobre as culturas.

Mokhtarian e Abbasi (2004) tratam do problema de representação de formas bi-dimensionais de cultivares onde a forma possui interseção com ela mesma. Isto é, uma parte do objeto fica escondida atrás de outra parte. As imagens foram representadas como *Curvature Scale Space* (CSS), pois esse tipo de representação detecta a interseção. A técnica tradicional de *matching* foi utilizada para classificar os objetos de acordo com a representação CSS. Essa abordagem foi testada em aplicações reais para encontrar, dada uma folha desconhecida, classes similares a partir de um banco de dados de imagens de folhas classificadas, representando diferentes variedades de plantas do gênero *chrysanthemum*. Esse método apresentou média de 90% de precisão. No nosso projeto, não é necessário representar as imagens como CSS pois não ocorre o tipo de interseção que essa representação foca. Além disso, a técnica de *matching* não pode ser utilizada para classificar os danos dos folíolos de soja pois os danos não são, necessariamente, iguais.

A similaridade de folhas de plantas é tratada em Nam et al. (2008). Para medir a similaridade, foram consideradas a forma e a disposição das nervuras como características. No domínio da forma, foi construída a matriz de pontos de interesse para modelar a similaridade entre duas imagens. A recuperação foi realizada por um algoritmo baseado no *Nearest Neighbor* (NN), que computa o peso mínimo da matriz construída e usa esse dado como grau de similaridade entre as imagens das folhas. Para o domínio da disposição das nervuras, foi construída uma matriz de adjacências da interseção e pontos finais das nervuras. Os resultados mostraram que o método proposto é mais eficiente que descritores de Fourier (Zahn e Roskies, 1972), momentos invariantes de Zernike (Kim e Kim, 2000), entre outros. Esse trabalho está relacionado com a classificação/identificação de folhas de plantas, e não pode ser aplicado para a classificação de lesões pois considera a disposição das nervuras da folha, que no nosso caso podem estar danificadas.

Em Wang et al. (2008), é proposto um método de classificação para imagens de folhas com fundo complexo. Inicialmente é realizada uma pré-segmentação e operações morfológicas para segmentar as imagens com fundo complexo baseado na prioridade da informação da forma. Depois, são utilizados os momentos de Hu e Zernike para extração das características da forma. A classificação das características é realizada pelo classificador *Moving Center Hypersphere* (MCH). Vinte classes de folhas de plantas foram classificadas com sucesso com 92.6% de precisão. Em nosso método, também foram utilizados os momentos de Zernike para extração de características, porém o fundo das nossas amostras é propositalmente homogêneo e branco.

O método descrito em Ling e Jacobs (2007) propõe a utilização de distância interna para construir descritores de forma que são robustos para articulação e captura de parte da estrutura. Além disso, a textura também foi utilizada para uma melhor classificação. Foi elaborado um método baseado em programação dinâmica para fazer o casamento da forma. Essa técnica foi testada em base de dados de folhas de plantas e apresentaram resultados satisfatórios, segundo os autores. Novamente, esse método não é adequado para o nosso problema pois a textura não caracteriza os danos dos nossos folíolos. Além disso, o algoritmo de casamento também não é suficiente para a classificação dos danos.

A identificação de folhas de milho danificadas por lagartas é realizada em Jr et al. (2003). As imagens das folhas foram processadas para criar imagens binárias onde as folhas foram segmentadas do fundo. Essas amostras foram então subdivididas em dois blocos e classificadas como danificadas ou não danificadas dependendo do número de objetos encontrados em cada bloco. O algoritmo classificou corretamente 95% das imagens testadas. Esse trabalho difere do nosso pois esse método diz apenas se a folha foi danificada ou não, já o nosso apresenta qual a praga danificou determinada região da folha.

Zhang e Meng (2011), Camargo e Smith (2009a) e Camargo e Smith (2009b) apresentam métodos para detecção e identificação de lesões em plantas baseados na cor e textura da lesão. Zhang e Meng (2011) propõem a detecção de bactérias (*citrus canker*) em folhas de cultivares. Os autores utilizam um algoritmo para selecionar as características mais importantes das lesões da folha para uma posterior segmentação da lesão do fundo. Após isso, um descritor de lesões *canker* é proposto, combinando cor e textura das zonas das lesões. Várias técnicas de classificação como *Radial Basis Network* (RBN), *Support Vector Machine* (SVM), entre outras, foram avaliadas e comparadas de acordo com as amostras da folhas. O método apresentou performance de classificação similar à classificação realizada por especialistas.

Já Camargo e Smith (2009a) apresentam um sistema para identificação de sintomas visuais de doenças de plantas. As regiões lesionadas foram segmentadas e características foram extraídas delas. A classificação das características foi realizada pelo SVM. Vários testes foram realizados e o estudo concluiu que a textura das características pode ser utilizada quando a imagem não possui cor ou forma definida no padrão.

Em outro trabalho, [Camargo e Smith \(2009b\)](#) descrevem um método baseado em processamento de imagens para identificar sintomas visuais de doenças de plantas usando a análise de imagens coloridas. O algoritmo de processamento converte as imagens RGB nas transformações de cor H (HSV ([Gonzalez et al., 2004](#))), I3a e I3b. As transformações I3a e I3b são modificações da transformação I1I2I3 ([Ohta et al., 1989](#)). A imagem é então segmentada por meio da análise da distribuição das intensidades do histograma. Após essa etapa, a região extraída é pós-processada para remover *pixels* que não são considerados na região desejada. Os resultados mostram que o algoritmo foi capaz de identificar regiões "doentes" mesmo se a região tem muitas intensidades de cor.

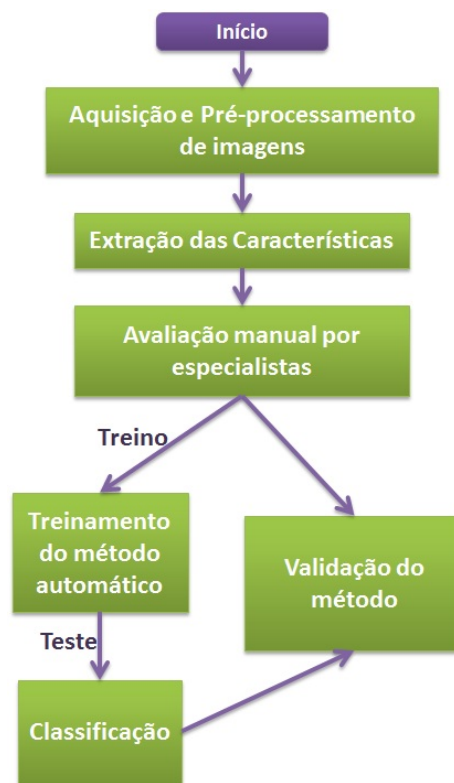
Esses três últimos trabalhos são semelhantes ao nosso, pois classificam as lesões das folhas, porém as características das lesões são baseadas em cor e textura, enquanto no nosso trabalho elas são baseadas no contorno. Além disso, o classificador que utilizamos (SVM) também foi testado nesses trabalhos, no entanto, neles a taxa de classificação foi baixa, inferior a 70%.

Por fim, [Backes et al. \(2009\)](#) introduzem uma metodologia para caracterização do contorno de formas, onde a forma é modelada como uma rede complexa. *Connectivity degree* e *joint degree* em uma evolução dinâmica de redes complexas são utilizados para compor o conjunto de descritores de forma. Os experimentos foram realizados com folhas de plantas e os descritores foram comparados com outros (descritores de Fourier, curvatura, momentos Zernike e fractal). A classificação foi realizada pelo método *Linear discriminat analysis* (LDA). Várias técnicas de extração de características apresentadas nesse artigo também foram utilizadas em nosso trabalho, como redes complexas, descritores de Fourier e momentos Zernike. Isso foi possível porque os descritores são baseados no contorno/área, então podem representar tanto folhas (como nesse trabalho) quanto danos (como no nosso projeto). Na parte de classificação, LDA não apresentou resultados satisfatórios com o nossos dados, então optamos pelo SVM.

Capítulo 3

Método Proposto

Neste capítulo, é apresentado o método proposto inicialmente em [Souza et al. \(2010\)](#) para classificação automática de agentes causadores de danos em folíolos de soja. Além disso, os descritores de características de Fourier, *Wavelet* e Zernike foram incorporados ao método ([Souza et al., 2011a](#)). A Figura 3.1 apresenta o diagrama com as etapas de desenvolvimento do método proposto.



(a)

Figura 3.1: Etapas de desenvolvimento do método proposto.

O método é composto por três passos principais: Pré-Processamento, Extração de Características e Classificação, descritos nas Seções 3.1, 3.2 e 3.3, respectivamente. O Pré-processamento consiste em eliminar resíduos e sombras das imagens dos folíolos, além de obter apenas os danos dos folíolos. A etapa de Extração de Características utiliza descritores de características para representar a informação visual contida nas imagens dos danos. Finalmente, a Classificação possui duas fases iniciais: avaliação manual por especialistas e treinamento do classificador. A partir da avaliação manual, o algoritmo classificador é treinado. Após o treinamento, o método é validado/testado (Capítulo 5).

3.1 Pré-Processamento das Imagens

Nessa etapa, é apresentado o pré-processamento aplicado à imagem do folíolo para obter o contorno do dano para os próximos passos de extração de características e classificação do dano. Esse pré-processamento pode ser subdividido em dois passos: filtragem da imagem do folíolo e extração do contorno do dano a partir da imagem do folíolo. O processo de filtragem aplicado à imagem do folíolo é o mesmo descrito em [Nazaré-Jr et al. \(2010\)](#), e ele envolve: remoção de sombras; eliminação de resíduos e objetos indesejáveis; binarização e recuperação do dano interno do folíolo. Essas etapas serão descritas a seguir.

A remoção de sombras é realizada usando uma conversão do espaço de cores RGB (*red, blue, green*) para o sistemas de cores HSV (*hue, saturation, value*). De acordo com [Nazaré-Jr et al. \(2010\)](#), ao convertermos a imagem para o espaço de cores HSV, somente o valor do canal H (*hue*) é suficiente para detecção e eliminação da região que representa a sombra da folha na imagem.

A eliminação de resíduos externos aos folíolos adquiridos durante a digitalização da imagem pode ser subdividida em três passos:

1. Segmentação da imagem: a segmentação utilizada consiste em detectar um limiar adequado usando o algoritmo de Otsu ([Otsu, 1979](#)), que definirá a região de interesse. O restante da amostra será considerado como fundo, de modo que o resultado dessa segmentação será uma imagem, em que toda região considerada como fundo terá *pixels* de cor branca ($R = G = B = 255$), e a região de interesse terá *pixels* de cor preta ($R = G = B = 0$).
2. Remoção de resíduos: após a segmentação, aplicamos um algoritmo de rotulação ([Gonzalez et al., 2004](#)). Isto irá determinar a maior região conexa dentro da imagem segmentada. Basta então descartarmos todas as outras regiões e dessa forma todos os resíduos externos à folha serão removidos.
3. Determinação do Fundo da Imagem: por fim, atribuímos a coloração branca ($R = G = B = 255$) a todos os *pixels* que não correspondem à região rotulada, para os três canais

do sistema RGB.

As regiões que ficaram na cor branca que estão dentro do folíolo são os danos internos que serão recuperados e será atribuída a cor preta a eles, enquanto o restante do folíolo será eliminado. A imagem da Figura 3.2b ilustra o resultado desse processo de filtragem, tendo como entrada a imagem da Figura 3.2a.

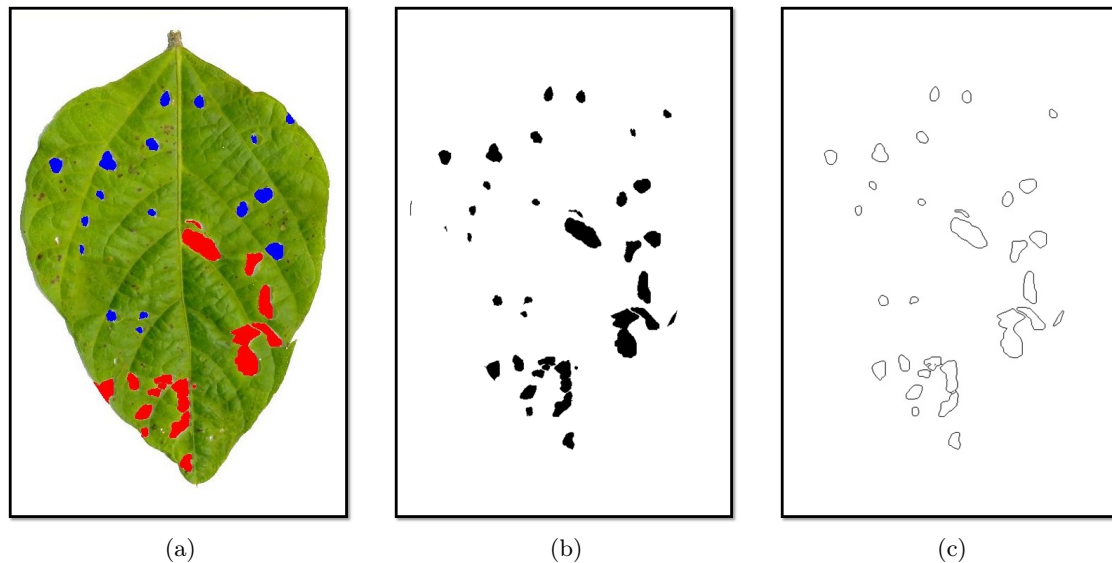


Figura 3.2: Exemplo ilustrativo: (a) Imagem de entrada com os danos rotulados; (b) Processo de filtragem [Nazaré-Jr et al. \(2010\)](#); (c) Extração do contorno do dano.

A partir da recuperação do dano interno do folíolo, extrai-se o contorno dos danos em três subpassos, como segue: 1) Danos com área menor do que 20 pixels (0,1 polegadas) são descartados, porque acredita-se que eles são menos significativos para prover o diagnóstico final para o folíolo pois até os humanos tem dificuldades para classificar esse tipo de dano; 2) Todos os contornos dos danos são facilmente computados como uma operação de diferença de conjuntos entre a imagem com os danos obtida usando o passo anterior e a imagem resultante de uma operação morfológica de erosão ([Gonzalez e Woods, 2007](#)). (Um exemplo de uma imagem resultante desse processo pode ser visualizada na Figura 3.2c tendo como entrada a imagem da Figura 3.2b.) 3) Uma vez que o contorno do dano é extraído, um algoritmo de rotação ([Gonzalez e Woods, 2007](#)) seguido de um processo de extração das *bounding boxes* é realizado para isolar e enumerar cada contorno dos danos.

3.2 Extração de Características

Os descritores de características são utilizados para extrair e representar a informação visual contida nas imagens. A seguir são apresentados os descritores utilizados em [Souza et al.](#)

(2011b), que são baseados em redes complexas, e os descritores de Fourier, Wavelet e Zernike, baseados em transformadas e momentos.

3.2.1 Descritores baseados em redes complexas

Uma vez que o contorno do dano é extraído, descrevemos como cada um deles é usado para modelar a rede complexa, e então como extrair características dessa rede.

De acordo com Backes et al. (2009), o domínio de redes complexas pode ser visto como a interseção de duas outras áreas importantes, Teoria dos Grafos e Estatística. Na literatura atual, são encontradas aplicações de redes complexas nos mais diversos ramos da Ciência da Computação, como mostrado em Antiqueira et al. (2007) e Chalumeau et al. (2006), que utilizam modelagem usando redes complexas em abordagens para correlação entre textos e discriminação de textura. Como em Backes et al. (2009), aplicamos redes complexas para análise do contorno das formas.

A modelagem apresentada em Backes et al. (2009) é baseada no modelo de rede de Watts-Strogatz (Watts e Strogatz, 1998). A forma é representada nos termos desse modelo seguida da análise de sua topologia e de suas características dinâmicas. Este modelo possui duas propriedades interessantes: 1) todos os vértices podem ser alcançados por qualquer outro com um número pequeno de arestas; 2) o grande número de ciclos mínimos (*e.g.*, tamanho 3) que o formam. Essas propriedades são definidas como propriedades de mundo pequeno. Adicionalmente, para extração de características, é necessário realizar uma evolução dinâmica que determina as arestas presentes na rede complexa por um valor limiar incrementado dinamicamente. A construção e evolução da rede será detalhada a seguir.

Construção da Rede Complexa

A fim de modelar o contorno de uma imagem/objeto por meio de uma rede complexa, o contorno da imagem é considerado como um conjunto de pontos $C = [p_1, p_2, \dots, p_n]$, em que p_i é um vetor de componentes (x_i, y_i) representando cada pixel pertencente ao contorno, onde x_i e y_i são suas coordenadas. Portanto, a rede será construída como um grafo onde cada pixel p_i é um vértice e cada aresta tem peso determinado pela distância Euclidiana entre seus vértices, *i.e.*,

$$d(p_i, p_j) = \sqrt{(x_i - x_j)^2 + (y_i - y_j)^2}. \quad (3.1)$$

Então é obtida a matriz W de tamanho $N \times N$, onde N representa o número de vértices da rede. A matriz é preenchida com os pesos das arestas calculados, *i.e.*,

$$w_{ij} = W([w_i, w_j]) = d(p_i, p_j). \quad (3.2)$$

Logo após, os valores da matriz são normalizados no intervalo $[0, 1]$, *i.e.*,

$$W = \frac{W}{\max w_{ij} \in W}. \quad (3.3)$$

Dessa forma, a rede obtida é uma rede regular, pois cada vértice possui uma aresta para todos os outros (grafo completo). No entanto, uma rede regular não é considerada uma rede complexa, pois não representa nenhuma propriedade relevante para nossa aplicação. Então, é necessário realizar uma transformação na rede de modo a obter uma rede complexa e assim obter propriedades importantes. Essa transformação é descrita como o próximo passo para a extração de características.

Evolução Dinâmica

Como mostrado anteriormente, o primeiro passo para o processo de extração de características é transformar a rede regular obtida em uma rede complexa. Então, um processo de evolução dinâmica de acordo com um limiar T_l é construído. A transformação δ é realizada como segue. A cada iteração l , todas as arestas com peso maior ou igual à T_l são removidas da rede regular. Então, é obtida uma nova rede complexa a cada iteração l , *i.e.*,

$$T_l = \delta_{T_l}(W) = \begin{cases} a_{ij} = 0, & \text{se } w_{ij} \geq T_l \\ a_{ij} = 1, & \text{se } w_{ij} < T_l \end{cases}. \quad (3.4)$$

A evolução de cada rede é garantida pelo uso de várias transformações δ onde o limiar T_l é incrementado sequencialmente de um valor T_{inc} . Então, dado um conjunto T , um elemento $T_l \in T$ é definido da seguinte forma:

$$T_l(k) = T_0 + kT_{inc}, \quad (3.5)$$

onde

$$T_{inc} = \frac{T_Q - T_0}{n - 1}, \quad 0 \leq k < n, \quad (3.6)$$

$$T_0 \leq T_l \leq T_Q, \quad (3.7)$$

T_0 e T_Q são os limiares inicial e final, respectivamente; e n é o número de intervalos na evolução dinâmica de rede complexa. Esses valores definem a evolução dinâmica, com um número finito de variações na rede complexa. A partir dessa evolução, as características são extraídas como segue.

Conectividade

A conectividade k_i de um vértice i corresponde ao número de arestas diretamente conectadas a esse vértice, e pode ser obtida por meio da matriz de adjacência A , *i.e.*,

$$k_i = \sum_{j=1}^N a_{ij}. \quad (3.8)$$

O primeiro vetor de características extraído para posterior classificação é composto por descritores de conectividade presentes nas diversas transformações da rede T_l . Para cada A_{T_l} obtido, dois valores são calculados que descrevem a conectividade de cada rede, *i.e.*, o grau médio (k_μ) e o grau máximo (k_K) de seus vértices, *i.e.*,

$$k_\mu = \frac{1}{N} \sum_{j=1}^N a_{ij}, \quad (3.9)$$

$$k_K = \max_i k_i. \quad (3.10)$$

Como demonstrado por [Backes et al. \(2009\)](#), é possível que essas características se tornem invariantes à rotação e a escala por meio de pequenos ajustes. A invariância à rotação é obtida pela normalização implementada na matriz W no intervalo $[0, 1]$. De outro lado, a invariância à escala pode ser alcançada por uma normalização de k_i pelo número de vértices (N) que compõem a rede, *i.e.*,

$$k_i = \frac{k_i}{N}, \text{ onde } 0 \leq i \leq N. \quad (3.11)$$

Então o vetor de características φ é obtido pela concatenação dos valores de grau médio (k_μ) e grau máximo (k_K) obtidos para cada estágio de evolução da rede utilizando determinados limiares no intervalo $[T_0, T_Q]$, *i.e.*,

$$\varphi = [k_\mu(T_0), k_K(T_0), k_\mu(T_1), k_K(T_1), \dots, k_\mu(T_Q), k_K(T_Q)].$$

Joint Degree

Em adição à conectividade, é possível examinar outras características sobre as redes complexas. Uma delas é o *joint degree* que determina medidas de correlação entre os graus dos vértices.

Para determinar essas medidas de *joint degree*, devemos conhecer a distribuição de probabilidade $P(k_i, k')_i$. Porém, no nosso método, considera-se $k_i = k'$, como sugerido em [Backes et al. \(2009\)](#). Assim, a distribuição $P(k_i, k_i)_i$ representa a probabilidade de um vértice i de grau k_i estar conectado a outro vértice de mesmo grau. Essa distribuição pode ser estimada a partir do grau de todos os vértices. Dessa forma, é possível determinar a probabilidade de conexão entre um vértice de grau k_i com outro k' analisando a matriz de adjacências. Sendo

assim, as características extraídas sobre o *joint degree* são: entropia, energia, e *joint degree* médio, que são descritas a seguir:

- *Entropia*: De acordo com [Backes et al. \(2009\)](#), a entropia está diretamente relacionada ao grau de desordem em um sistema. O cálculo da entropia pode ser definido como:

$$H = - \sum_{i=1}^N P(k_i, k'_i) \log_2 P(k_i, k'_i). \quad (3.12)$$

- *Energia*: A energia pode ser definida pela seguinte expressão:

$$E = - \sum_{i=1}^N (P(k_i, k'_i))^2. \quad (3.13)$$

- *Joint Degree Médio*: Essa medida denota a probabilidade média de encontrar dois vértices arbitrários de mesmo grau na rede, considerando todas as possibilidades

$$P = \frac{1}{N} \sum_{i=1}^N P(k_i, k'_i). \quad (3.14)$$

3.2.2 Descritores baseados no contorno

É importante obter uma representação do contorno que facilite o cálculo desse tipo de descritores. Utilizamos então o algoritmo seguidor de fronteira descrito em [Gonzalez e Woods \(2010\)](#), de forma que seja possível determinar a sequência de pontos $s = (p_1, p_2, \dots, p_n)$ que compõe o contorno ou região. Segundo esse algoritmo, dada uma região R , a metodologia para seguir seu contorno consiste das seguintes etapas:

1. O ponto de partida b_0 é o ponto mais alto e mais à esquerda na imagem que pertença ao objeto. Examine os 8 vizinhos de b_0 a partir de seu vizinho a oeste (c_0). Seja b_1 o primeiro vizinho encontrado e seja c_1 o ponto imediatamente anterior a b_1 , a localização de b_0 e b_1 deve ser conservada.
2. Considere que $b = b_1$ e $c = c_1$.
3. Faça com que os 8 vizinhos de b , a partir de c e seguindo no sentido horário, sejam indicados por n_1, n_2, \dots, n_8 . Encontre o primeiro n_k rotulado com 1 (pertencente ao objeto).
4. Considere que $b = n_k$ e $c = n_{k-1}$.

5. Repita as etapas 3 e 4 até que $b = b_0$ e o próximo ponto de fronteira encontrado seja b_1 . A sequência de pontos b encontrada quando o algoritmo para constitui o conjunto de pontos do contorno ordenado.

A ilustração da Figura 3.3 apresenta os primeiros passos do algoritmo seguidor de fronteira. O ponto a ser processado a seguir é indicado em preto, os pontos que ainda serão processados são vermelhos e os pontos encontrados pelo algoritmo são indicados como quadrados cinza (Gonzalez e Woods, 2010).




Figura 3.3: Exemplo dos primeiros passos do algoritmo seguidor de fronteira.

Outra ação necessária para extração desses descritores foi normalizar o tamanho dos danos, para que todos tenham o mesmo padrão em relação ao tamanho e assim sejam invariantes à escala. Além disso, normalizamos também o local dos danos. Todos foram transladados para seus centros de massa. Isso garante a invariância à translação dos descritores que serão calculados.

3.2.2.1 Descritores de Fourier

A principal ideia desse tipo de descritor é caracterizar o contorno como um conjunto de números que representam o conteúdo de frequência de toda a forma, no caso, do dano do folíolo. Baseado na análise da frequência, é possível selecionar um pequeno conjunto de números (coeficientes de Fourier) que descreve a forma/dano.

As imagens da Figura 3.4 apresentam um exemplo da transformada de Fourier para um dano de folíolo de soja. O contorno do dano é levado ao domínio de frequência pela transformada de Fourier. Posteriormente são escolhidos 50 desses descritores de Fourier para reconstruir o dano original.

Para obter os coeficientes de Fourier, inicialmente o dano é descrito pelas coordenadas do contorno, escritas como um número complexo

$$s(k) = x(k) + jy(k) \quad (3.15)$$

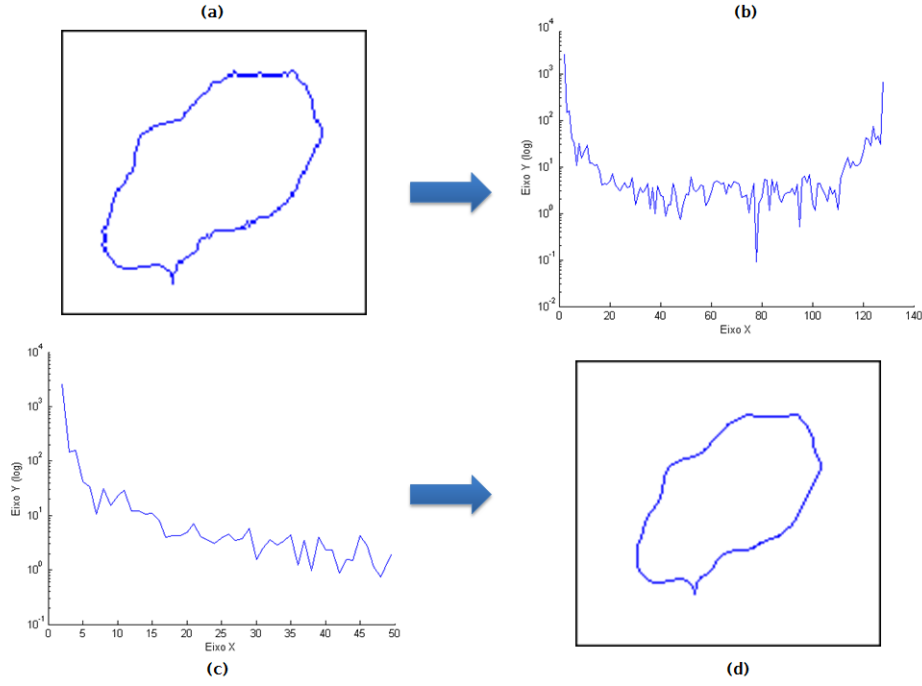


Figura 3.4: Exemplo ilustrativo: (a) Dano original; (b) Dano no domínio da frequência; (c) 50 primeiros coeficientes de Fourier do dano; (d) Dano reconstruído a partir dos coeficientes de Fourier apresentados (c).

para $k = 0, 1, 2, \dots, K - 1$, onde K é a quantidade de pontos do contorno e $j = \sqrt{-1}$. Ou seja, o eixo x é tratado como real e o eixo y como eixo imaginário de uma sequência de números complexos.

A transformada discreta de Fourier (DFT) (Briggs e Henson, 1995) de $s(k)$ é

$$a(u) = \sum_{k=0}^{K-1} s(k) e^{-j2\pi uk/K} \quad (3.16)$$

para $u = 0, 1, 2, \dots, K - 1$. Os coeficientes complexos $a(u)$ são chamados de *descritores de Fourier* do contorno. A transformada inversa de Fourier desses coeficientes reconstrói $s(k)$. Isto é,

$$s(k) = \frac{1}{K} \sum_{u=0}^{K-1} a(u) e^{-j2\pi uk/K} \quad (3.17)$$

para $k = 0, 1, 2, \dots, K - 1$. Apenas os primeiros P coeficientes de Fourier (coeficientes de menor frequência) são usados como características (Gonzalez e Woods, 2010), isto é, para $u \geq P$, $a(u) = 0$. O resultado é a seguinte *aproximação* para $s(k)$:

$$\hat{s}(k) = \frac{1}{P} \sum_{u=0}^{P-1} a(u) e^{-j2\pi uk/P} \quad (3.18)$$

para $k = 0, 1, 2, \dots, K-1$. Embora apenas P termos sejam usados para obter cada componente de $\hat{s}(k)$, k ainda varia de 0 a $K-1$. Ou seja, o mesmo número de pontos existe no contorno aproximado, mas não são utilizados tantos termos na reconstrução de cada ponto.

A Figura 3.5a mostra o contorno de um dano de um folíolo de soja com 280 pontos. As outras imagens mostram os contornos reconstruídos usando 50, 40, 30, 20, 10, 5 e 2 descritores de Fourier, respectivamente.




Figura 3.5: Exemplo ilustrativo: (a) Contorno de um dano com 280 pontos; (b) a (h) Contornos reconstruídos usando 50, 40, 30, 20, 10, 5 e 2 descritores.

Os componentes da transformada de Fourier de alta frequência são responsáveis pelos detalhes finos e os componentes de baixa frequência determinam a forma global da imagem. Assim, quanto menor P for ficando, mais detalhes são perdidos no contorno.

Poucos descritores de Fourier são suficientes para capturar a essência geral de um contorno (Gonzalez e Woods, 2010). Essa propriedade é importante porque esses coeficientes carregam informações sobre o formato. Assim, eles podem ser usados como base para discriminar formatos de fronteiras, como desejamos para diferenciar os contornos dos danos.

A representação do contorno no domínio da frequência permite que simples transformações o tornem invariante à rotação, translação e escala (Osowski e Nghia, 2002). A invariância ao ponto de partida também garante que a representação seja invariante à rotação.

Para que o contorno seja invariante ao ponto de partida, é necessário redefinir a Equação 3.15 e obter $s_p(k)$, que representa as coordenadas complexas com o ponto de partida invariante. Dessa forma, $s_p(k)$ é definido como:

$$s_p(k) = s(k - k_0), \quad (3.19)$$

então

$$s_p = x(k - k_0) + jy(k - k_0), \quad (3.20)$$

onde k representa um ponto do contorno e k_0 representa um ponto de partida predefinido. Nesse caso, escolhemos k_0 como o ponto de maior magnitude. Assim, o que muda mesmo é somente o ponto de partida da sequência de $k = 0$ para $k = k_0$.

Além disso, uma importante vantagem da transformada de Fourier é que seus descritores são fortemente imunes ao ruídos (Nixon e Aguado, 2008).

3.2.2.2 Descritores *Wavelet*

A transformada *Wavelet* consiste em um tipo de representação tempo-frequência de sinais que pode permitir que se tenha simultaneamente boa resolução em tempo e em frequência (Mallat, 2004).

A transformada *Wavelet* é uma transformação que decompõe o sinal em diferentes níveis. A decomposição é realizada por meio de uma série de funções elementares, criadas a partir de escalamentos e translações de uma função de base, denominada “*wavelet* mãe”. Utilizamos as funções de base Haar, Daubechies 2 e Daubechies 3.

Em nosso caso, a transformada discreta *Wavelet* é aplicada representando o dano do folíolo em vários níveis, diferenciando na quantidade dos detalhes (Figura 3.6).




Figura 3.6: Exemplo da Transformada *Wavelet* decompondo um sinal S em 3 níveis. A e D representam os sinais de aproximação e detalhe, respectivamente.

Ao aplicar *wavelets* às representações do dano, é necessário escolher um número limite de níveis e normalizar os coeficientes para prover invariâncias à translação, escala e rotação. Esses coeficientes são chamados descritores *Wavelet*.

Os descritores *Wavelet* são formados na base da representação *wavelet* da sequência original (x_i, y_i) , descrevendo o contorno do dano do folíolo. Essa representação pode ser apresentada na forma:

$$\begin{bmatrix} x(l) \\ y(l) \end{bmatrix} \cong \begin{bmatrix} x_a(l) \\ y_a(l) \end{bmatrix} + \sum_{m=k}^M \begin{bmatrix} x_{dm}(l) \\ y_{dm}(l) \end{bmatrix}, \quad (3.21)$$

onde $x_a(l)$ e $y_a(l)$ são os sinais de aproximação e $x_d(l)$ e $y_d(l)$ são os sinais de detalhe correspondentes ao l -ésimo ponto da sequência.

Os sinais de aproximação são expressados usando funções de escala ϕ_{mn} :

$$\begin{aligned} x_a(l) &= \sum_n a_n \phi_{Mn}(l) \\ y_a(l) &= \sum_n c_n \phi_{Mn}(l), \end{aligned} \quad (3.22)$$

onde M é o nível máximo de decomposição; n é o índice de translação; e a_n e c_n são os coeficientes de aproximação.

Os sinais de detalhe são expressados usando funções *wavelet* ψ_{mn} :

$$\begin{aligned} x_{dm}(l) &= \sum_n r_{mn} \psi_{mn}(l) \\ y_{dm}(l) &= \sum_n d_{mn} \psi_{mn}(l), \end{aligned} \quad (3.23)$$

onde $m = 1, 2, \dots, M$ indica os níveis de decomposição; r_{mn} e d_{mn} são os coeficientes de detalhe.

Os descritores *Wavelet* são construídos com os coeficientes a_n e c_n , representando o sinal de aproximação. O conjunto de r_{mn} e d_{mn} ($m = 1, 2, \dots, M$), representando os sinais de detalhe de M níveis de decomposição são descartados pois não aguardam informações relevantes para descrição dos danos.

Ao calcular os coeficientes de detalhe e aproximação, o algoritmo executa até que a quantidade de coeficientes reduza à quantidade desejada. A partir dos coeficientes resultantes, são considerados descritores os primeiros $pSize\%$ valores (maiores valores em módulo), onde $pSize$ é o percentual passado pelo usuário. Caso a quantidade de valores resultante seja menor que a desejada pelo usuário, o vetor é completado com valores iguais a 0. A quantidade de descritores pode ser menor que a deseja pois não há um controle exato para gerar determinados descritores. A cada iteração da transformada *Wavelet* os dados são reduzidos sem seguir um padrão exato. Ao final do processo, foi necessário normalizar os descritores dividindo todos pelo valor do maior descritor.

A imagens da Figura 3.7 apresentam a reconstrução do contorno (Figura 3.5a) de 280 pontos depois de aplicada a transformada *Wavelet*. É possível ver nas imagens que essa

transformada é uma suavização do sinal. O contorno foi reconstruído com 128, 66, 35, 20, 12 e 8 descritores *Wavelet*, respectivamente. Como explicado acima, não é possível definir exatamente esses valores.

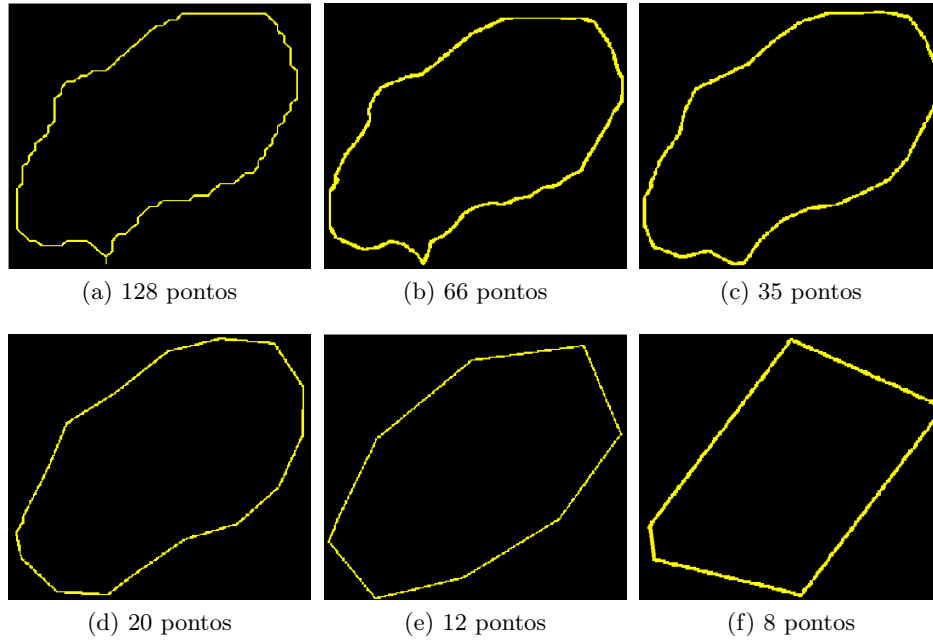


Figura 3.7: (a) a (f) Contornos reconstruídos usando 128, 66, 35, 20, 12 e 8 descritores *wavelet*.

3.2.3 Descritor baseados na área

O único descritor que utilizamos que não tem como base o contorno do dano é o descritor Zernike. Esse tipo de descritor utiliza a área do dano para extrair informações importantes que o representam.

3.2.3.1 Descritores de Zernike

Diferentemente dos descritores de Fourier e *Wavelet* que são baseados no contorno do dano, esse descritor é baseado na região/área do dano. O objetivo é calcular os momentos de Zernike. Segundo [Nixon e Aguado \(2008\)](#), momentos são descritores globais de forma, e possuem a mesma vantagem dos descritores de Fourier, a habilidade de discernir e filtrar ruídos. Os momentos concentram na densidade da região e foram introduzidos para utilização com imagens por [Hu \(1962\)](#). Momentos fornecem uma descrição global com propriedade de invariância e com as vantagens de uma descrição compacta com o objetivo de evitar o efeito de ruídos.

Os momentos de Zernike são invariantes à rotação e translação. A invariância à rotação é alcançada através da utilização de coordenadas polares. Esses momentos são a projeção da função da imagem em funções da base ortogonal. Essas funções são polinômios na forma

$$V_{nm}(x, y) = V_{nm}(\rho, \theta) = R_{nm}(\rho)e^{jm\theta}, \quad (3.24)$$

onde $n - |m|$ é par e $0 \leq |m| \leq n$.

A ordem do polinômio é denotada por n e a repetição por m ; ρ é o tamanho do vetor da origem até o pixel (x, y) ; θ é o ângulo entre o vetor ρ e o eixo x ; e $R_{nm}(\rho)$ é o polinômio radial definido como:

$$R_{nm}(\rho) = \sum_{s=0}^{(n-m)/2} \frac{(-1)^s [(n-s)!] \rho^{n-2s}}{s! \left(\frac{n+|m|}{2} - s\right)! \left(\frac{n-|m|}{2} - s\right)!}. \quad (3.25)$$

Como m pode ter valores negativos, o polinômio radial usa sua magnitude e assim, o relacionamento inverso é: $R_{n,m}(\rho) = R_{n,-m}(\rho)$. Os seis primeiros polinômios radiais ortogonais são:

$$\begin{aligned} R_{00}(\rho) &= 1 & R_{11}(\rho) &= r \\ R_{20}(\rho) &= 2r^2 - 1 & R_{22}(\rho) &= r^2 \\ R_{31}(\rho) &= 3r^3 - 2r & R_{33}(\rho) &= 2r^2 - 1 \end{aligned} \quad (3.26)$$

Esses polinômios são ortogonais e satisfazem:

$$\int \int_{x^2+y^2 \leq 1} [V_{nm}(x, y)] V_{pq}(x, y) dx dy = \frac{\pi}{n+1} \delta_{np} \delta_{mq}, \quad (3.27)$$

$$\delta = \begin{cases} 1, (a = b), \\ 0, \text{Caso contrário.} \end{cases} \quad (3.28)$$

Esses polinômios formam um conjunto ortogonal completo no interior de um círculo unitário de $x^2 + y^2 = 1$. Para computar os momentos de Zernike de uma imagem, o centro da imagem é tomado como a origem e as coordenadas dos pixels são mapeadas para o intervalo do círculo unitário (Zhenjiang, 2000). Os pixels que ficarem fora desse círculo não são utilizados para a computação. Enfim, o momento de Zernike de ordem n com repetição m para uma função $f(x, y)$ de um imagem digital que desaparece fora do círculo unitário é:

$$Z_{nm} = \frac{n+1}{\pi} \sum_x \sum_y f(x, y) V_{nm}(\rho, 0), \quad \text{onde } x^2 + y^2 \leq 1. \quad (3.29)$$

3.3 Classificação

Aprendizado de máquina é uma área de Inteligência Artificial cujo objetivo é o desenvolvimento de técnicas computacionais sobre o aprendizado bem como a construção de sistemas capazes de adquirir conhecimento de forma automática. Um sistema de aprendizado é um programa de computador que toma decisões baseadas em experiências acumuladas por meio da solução bem-sucedida de problemas anteriores (Rezende, 2005). Isto é, a partir das amostras de treinamento, o computador deve aprender ou estimar as características desconhecidos de um modelo, como apontar se um dano pertence à classe de lagartas ou de coleópteros.

Em nosso método, o aprendizado é supervisionado, ou seja, um especialista disponibilizou rótulos para cada padrão/dano do conjunto de treinamento. O algoritmo de aprendizado de máquina deve então extrair informações relevantes a partir do treinamento para gerar saídas corretas para amostras que não foram apresentadas previamente (etapa de teste) (Duda et al., 2001). Dado o conjunto de danos rotulados com sua classe de agente danificador, deve-se produzir um classificador capaz de prever o rótulo de danos desconhecidos.

Uma característica importante que o classificador deve ter é a de generalização. O algoritmo deve prever corretamente a classe de novas amostras e não acertar apenas na classificação das amostras utilizadas para o treinamento.

Na Seção 3.2, as características dos danos foram extraídas e para discriminar as duas classes de agentes danificadores, *i.e.*, coleópteros e lagartas, utilizaremos o algoritmo de aprendizado de máquina *Support Vector Machines* (SVM).

3.3.1 *Support Vector Machines* - SVM

Support Vector Machines (SVM) (Cortes e Vapnik, 1995) é um algoritmo de aprendizado de máquina para resolução de problemas de classificação e regressão. Uma importante propri-

idade desse algoritmo é que a determinação dos parâmetros do modelo corresponde a um problema de otimização convexa, e assim qualquer solução local também é um ótimo global (Bishop, 2006), (Theodoridis e Koutroumbas, 2008).

Support Vector Machines constrói classificadores criando hiperplanos em um espaço n -dimensional. Quando confrontados com problemas não-lineares, o SVM cria um mapeamento entre um conjunto de amostras de entrada e um espaço de características (Figura 3.8), onde essas classes não-lineares são feitas linearmente separáveis por uma transformação (ou mapeamento) do espaço de características. Esse mapeamento é feito por um conjunto de funções matemáticas chamadas *kernels* (ϕ).




Figura 3.8: Exemplo SVM - Mapeamento do espaço de características

Dado um conjunto com l pares de amostras de treinamento $(s_i, t_i), i = 1, \dots, l$ onde $s_i \in R^n$ e $t \in \{1, -1\}^l$, t_i é 1 ou -1 para indicar a classe que o ponto s_i pertence. Cada s_i é um vetor real n -dimensional. Precisamos então encontrar o hiperplano com maior margem que divide as amostras onde $t_i = 1$ daquelas onde $t_i = -1$, e obter também o menor erro de generalização.

Ao determinar o hiperplano que separa as amostras das classes de forma a colocar o maior número de amostras da mesma classe do mesmo lado, o SVM se preocupa em maximizar a distância de cada classe a esse hiperplano. A distância de uma classe a um hiperplano é a menor distância entre ele e as amostras dessa classe e é chamada de margem de separação. O hiperplano gerado pela SVM é determinado por um subconjunto das amostras das duas classes, chamado de **vetores de suporte**.

Existem vários hiperplanos que separam as amostras, mas há somente um que maximiza a margem (Figura 3.9), ou seja, maximiza a distância entre as amostras mais próximas de cada classe e o hiperplano de separação. Esse hiperplano ótimo gera o menor erro de generalização do classificador.

Deste modo, máquinas de vetores de suporte (SVM) requerem a solução do seguinte problema de otimização:

$$\min_{w,b,\xi} \quad \frac{1}{2}w^T w + C \sum_{i=1}^l \xi_i \quad (3.30)$$




Figura 3.9: Exemplo SVM - Maximização da margem: (a) Separação perfeita, mas não ótima; (b) Separação ótima.

sujeito a

$$t_i(w^T \phi(s_i) + b) \geq 1 - \xi_i, \quad (3.31)$$

$$\xi_i \geq 0. \quad (3.32)$$

Analisando a Equação 3.30, SVMs minimizam w , b e ξ_i , onde w é o vetor normal ao hiperplano; $\frac{b}{\|w\|}$ é a distância da origem do hiperplano até o vetor normal w ; e ξ_i é uma variável de folga que mede o grau de erros na classificação de s_i . Minimizar w e b garantem a maximização da margem. Por outro lado, como os dados podem ser não-lineares, é necessário permitir que algumas amostras sejam classificadas incorretamente (o mínimo possível) e por isso ξ_i também é minimizado. A variável de folga ξ_i recebe uma penalidade C quando ξ_i é diferente de zero, para garantir que a menor quantidade de dados seja classificada de forma errada. Além disso, a restrição apresentada na Equação 3.31 garante uma margem com distância significativa entre as amostras das duas classes.

Para dados não-lineares no treinamento, é importante escolher adequadamente a função de mapeamento (ϕ), pois o desempenho do SVM depende amplamente da função *kernel* utilizada. Os principais *kernels* utilizados são:

- linear: $K(s_i, s_j) = s_i^T s_j$.
- polinomial: $K(s_i, s_j) = (\gamma s_i^T s_j + r)^d, \gamma > 0$.
- função de base radial (RBF): $K(s_i, s_j) = \exp(-\gamma \|s_i - s_j\|^2), \gamma > 0$. Algumas vezes parametrizado utilizando $\gamma = \frac{1}{2\sigma^2}$, para $\sigma \in \mathbb{R}^+$.
- sigmoide: $K(s_i, s_j) = \tanh(\gamma s_i^T s_j + r)$.

onde γ , r , e d são parâmetros de *kernel*.

No nosso método, escolhemos o *kernel* de função de base radial (RBF). Essa função foi escolhida pelas três razões descritas a seguir (Hsu et al., 2010):

1. O *kernel* RBF mapeia não-linearmente amostras em um espaço dimensional mais alto e isso, diferente do *kernel* linear, pode lidar com o caso em que a relação entre os rótulos e atributos das classes são não-lineares. Além disso, o *kernel* linear é um caso especial do RBF, desde que o *kernel* linear com o parâmetro de penalidade \tilde{C} tenha a mesma exatidão do *kernel* RBF com alguns parâmetros (C, γ) . O *kernel* sigmoide também se comporta como o RBF para certos parâmetros.
2. O *kernel* polinomial tem mais parâmetros que o RBF, e isso influencia a complexidade da seleção do modelo.
3. O RBF possui menos dificuldades numéricas. Um ponto chave é $0 < K_{ij} \leq 1$ em contraste com a função polinomial onde os valores do *kernel* podem ir ao infinito ($\gamma x_i^T x_j + r > 1$) ou zero ($\gamma x_i^T x_j + r < 1$) quando o grau é grande.

Além da seleção do *kernel*, a acurácia do algoritmo SVM também depende dos parâmetros do *kernel* e da variável de folga C . Como utilizamos o *kernel* RBF, temos um parâmetro para o *kernel* (γ) . Os melhores valores de C e γ foram selecionados através de uma busca *grid* com sequências de C e γ variando exponencialmente (Hsu et al., 2010).

3.4 Considerações Finais

Neste capítulo, foram descritas as etapas para o método de caracterização automática de agentes causadores de danos em folíolos de soja. O próximo passo então é avaliar o método proposto através de experimentos, ou seja, verificar se o classificador (SVM) conseguiu discriminar significativamente as classes dos agentes causadores de danos nos folíolos de soja, *i.e.*, *coleópteros* e *lagartas*. Esses experimentos, assim como a análise dos mesmos, serão apresentados no Capítulo 5. Eles mostram a precisão e sensibilidade de classificação do SVM para os diferentes tipos de descritores utilizados.

Como explicado na Seção 3.3, é necessário treinar o algoritmo SVM com um conjunto de amostras rotuladas referente a qual classe pertencem. Essa rotulação foi realizada por um especialista e o próximo capítulo apresenta a plataforma web que criamos para tal avaliação.

Capítulo 4

Sistema Web

O método de caracterização automática dos agentes causadores de danos em folíolos de soja requer a etapa de classificação (Seção 3.3), realizada pelo SVM. Para o treinamento supervisionado do SVM, é necessário que os danos sejam previamente rotulados, assim o SVM aprende quais as características de danos pertencem a cada classe. Essa avaliação prévia dos danos foi realizada por um especialista da Universidade Federal de Viçosa.

Para a avaliação manual das amostras realizada por especialistas, foi implementada inicialmente uma aplicação de fácil acesso, onde o usuário pode avaliar cada região danificada na amostra (Souza et al., 2010). Esse sistema foi incrementado com outras funcionalidades e está disponível via *Web* pois o especialista contactado não está na nossa universidade e sim na Universidade Federal de Viçosa. Outra motivação para a criação de uma interface via *Web* é a possibilidade de trabalhar com especialistas de qualquer lugar do mundo. Além disso, essa interface pode ser adaptada para ser utilizada em qualquer outra aplicação que envolva rotulação de dados para aprendizado de máquina.

Essa aplicação foi desenvolvida em *Java* na forma de *applet*. Um *applet* é um programa *Java* capaz de ser executado em qualquer navegador *Web* que tenha o *Java* ativado. Além disso, o *Java* oferece a portabilidade de funcionar corretamente em qualquer arquitetura e sistema operacional. Dessa forma os usuários não possuem restrição de utilizar o programa em uma arquitetura, sistema operacional ou navegador específico. Ao se escolher um *applet* no navegador, o programa *Java* é carregado do servidor remoto para a máquina cliente (navegador *Web*) e é executado localmente.

Foram disponibilizadas 178 amostras de folíolos de soja para avaliação. Essas amostras são exibidas em um painel interativo (veja Figura 4.1), onde o usuário deve clicar em cada uma das regiões lesionadas na folha para atribuir uma das opções de avaliação (coleóptero ou lagarta). Para isso, foram utilizadas classes da biblioteca *Java Advanced Imaging*, apresentada por Microsystems (1999) e Miranda (2006).

A biblioteca *Java Advanced Imaging*-JAI estende a plataforma *Java* permitindo um processamento de imagens sofisticado e de alto desempenho incorporado em *Java applets* e apli-

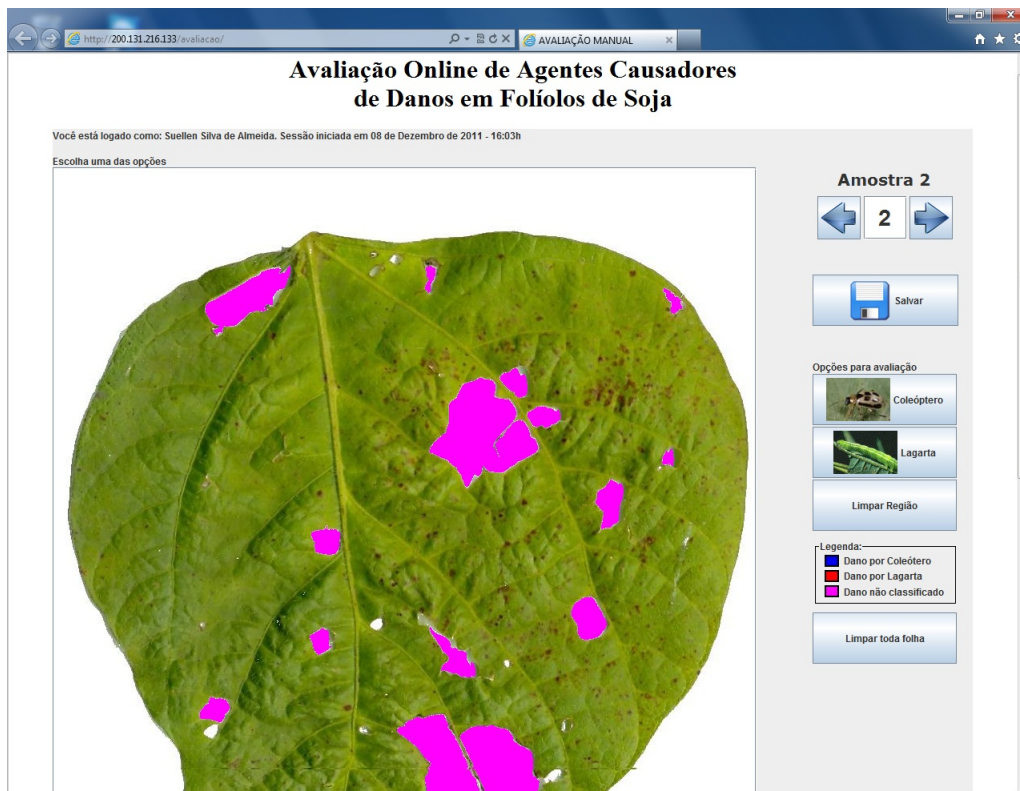


Figura 4.1: *Print Screen* do Sistema Web para avaliação dos danos dos folíolos de soja

cações. A JAI possui várias operações de processamento de imagens e também é extensível para que novas operações sejam adicionadas como se fossem nativas. Essa biblioteca foi escolhida pois dá suporte ao processamento de imagens na linguagem *Java* da forma mais geral possível, apresentando um modelo de programação que pode ser facilmente utilizado em aplicações sem que o programador necessite implementar muitas linhas de código. Além disso, JAI não assume um formato de dados particular. Imagens podem ser manipuladas sem que o programador tenha conhecimento sobre o formato que está sendo utilizado.

A seguir são descritas as principais funcionalidades do sistema:

- Rotulação dos danos: essa funcionalidade permite que o usuário avalie um dano causado por lagarta ou por coleóptero. Inicialmente, todos os danos que serão utilizados para aprendizado (treinamento e teste) do método automático estão na cor magenta. Esses danos são os extraídos como apresentado na Seção 3.1. Assim, o usuário visualiza quais danos devem ser classificados. Então basta escolher o agente causador do dano e clicar em cima do dano que ficará vermelho caso o usuário tenha escolhido lagarta e azul se a opção escolhida foi coleóptero.
- Limpeza da avaliação: após avaliar os danos, se o usuário desejar mudar alguma avaliação, ele pode refazer sua escolha, clicar no dano e ele ficará com a cor correspondente.

Porém, se o usuário desejar descartar toda a avaliação, basta ele clicar no botão correspondente a essa funcionalidade e todos os danos voltarão a cor inicial (magenta), sem classificação.

- Salvar avaliação da folha: como precisamos da avaliação de cada dano de todas as folhas de soja disponíveis, após avaliar os danos de uma amostra, o usuário deve salvar essa avaliação. As avaliações são salvas em um banco de dados local do nosso laboratório para que possamos ter acesso posteriormente. Se o usuário não avaliar todos os danos de uma folha e mesmo assim quiser salvar, é permitido, porém uma mensagem de alerta é exibida para que o usuário confirme que realmente deseja salvar sem classificar todos os danos. Dessa forma, o usuário pode salvar uma avaliação parcial da folha e continuar avaliando em outro momento.
- Exibição das amostras: os folíolos de soja estão numerados de 1 a 178. Ao entrar na plataforma, a amostra 1 é exibida e após salvar a avaliação da folha atual, automaticamente a próxima amostra é carregada. Além disso, o sistema possui a funcionalidade de exibir uma amostra específica de acordo com o desejo do usuário.
- Mensagens de erro e alerta: durante a utilização do sistema, podem ser exibidas mensagens de erro para ações que não são permitidas e mensagens de alerta para que o usuário não faça algo sem ter certeza do que deseja. Essas mensagens garantem a consistência da aplicação.

Após finalizar a avaliação de todas as folhas, no nosso banco de dados local possuímos as seguintes informações: número da folha, coordenadas do dano e agente danificador atribuído (lagarta ou coleóptero). Utilizamos então esses dados rotulados para aprendizado supervisionado do nosso método automático.

Capítulo 5

Experimentos

Este capítulo apresenta, discute e analisa os resultados dos experimentos realizados utilizando o método proposto, a fim de validá-lo. Ele está organizado da seguinte maneira. Primeiro (Seção 5.1), a base de dados utilizada para os experimentos é descrita. A seguir, na Seção 5.2 são relatadas as etapas de treinamento e testes do algoritmo de aprendizado de máquina SVM. A Seção 5.3 descreve e analisa os resultados obtidos utilizando os descritores baseados em redes complexas (Subseção 5.3.1), descritores de Fourier (Subseção 5.3.2), descritores *Wavelet* (Subseção 5.3.3) e descritores de Zernike (Subseção 5.3.4). A Seção 5.4 apresenta uma análise estatística dos resultados a fim de mostrar o quão robustos são os resultados obtidos. Na Seção 5.5, é realizada uma análise de todos os resultados apresentados. Por fim, a seção 5.6 mostra um exemplo ilustrativo da classificação obtida para um folíolo de soja com os vários descritores utilizados.

5.1 Base de Dados

A fim de treinar, testar e validar nosso método, utilizamos uma base de dados com 178 amostras de folíolos de soja retirados aleatoriamente de campos experimentais do Departamento de Fitotecnia da Universidade Federal de Viçosa. Todas as amostras foram digitalizadas com resolução de 200 dpi. Exemplos dessas amostras são apresentados na Figura 5.1.




Figura 5.1: Exemplo das amostras de folíolos de soja da nossa base de dados.

Como nosso foco é nos danos dos folíolos, essa base de dados foi avaliada por um especialista usando a plataforma web descrita no Capítulo 4. A partir dessa avaliação, foi gerada uma base de dados *ground-truth* com 1780 imagens de danos, onde 1170 amostras foram rotuladas como causadas por lagartas e 610 por coleópteros. A Tabela 5.1 apresenta os dados estatísticos sobre a base de dados descrita.

Tabela 5.1: Dados estatísticos sobre a base de amostras

Classe	Total	# por Folha		
		min - max	μ	$\pm \sigma$
Coleóptero	610	[0 - 20]	3.4	± 3.1
Lagarta	1170	[0 - 20]	6.5	± 4.2
Total	1780	[1 - 30]	9.9	± 6.2

A Tabela 5.1 apresenta o total de danos pertencentes às classes coleóptero e lagarta, assim como o total de danos presentes nas amostras. Além disso, são exibidos os dados estatísticos de danos por folha de acordo com cada classe: quantidade mínima (*min*) e máxima (*max*), média (μ) e desvio padrão (σ). Estes dados mostram que há um desbalanceamento entre as classes dos agentes danificadores, isto é, existem mais danos da classe das lagartas do que da classe dos coleópteros. A Figura 5.2 ilustra a distribuição estatística dos agentes causadores de danos para todas as folhas da base de dados, ou seja, apresenta a quantidade de danos de coleópteros e lagartas de cada folha da base.

5.2 Treino e Teste do SVM

Como explicado no Capítulo 3, escolhemos o algoritmo *Support Vector Machines* (SVM) para classificação dos danos pois este algoritmo apresenta os melhores resultados na literatura atual. Utilizamos o SVM com *kernel* de função de base gaussiana radial e o algoritmo foi executado utilizando o pacote LIBSVM (Chang e Lin, 2011). Utilizamos ferramentas desse mesmo pacote para estimar os melhores valores para os parâmetros C e γ do SVM (Figura 5.3). Esses parâmetros, se bem estimados, auxiliam em uma melhor classificação das classes (coleópteros e lagartas) pelo SVM.

A Figura 5.3 ilustra como a ferramenta do pacote LIBSVM estima os melhores valores para os parâmetros C e γ do SVM. É possível ver que a ferramenta realiza uma busca *grid* com as sequências de C e γ variando exponencialmente. Os melhores valores para C e γ são os que resultam na maior acurácia e estão apresentados na imagem usando um círculo verde. Essa estimativa foi feita utilizando 10% das amostras.

O classificador foi treinado/testado com o esquema de validação cruzada *leave-one-out*, que é uma variante do *leave-k-out*, em que k é variável, representando o número de amostras

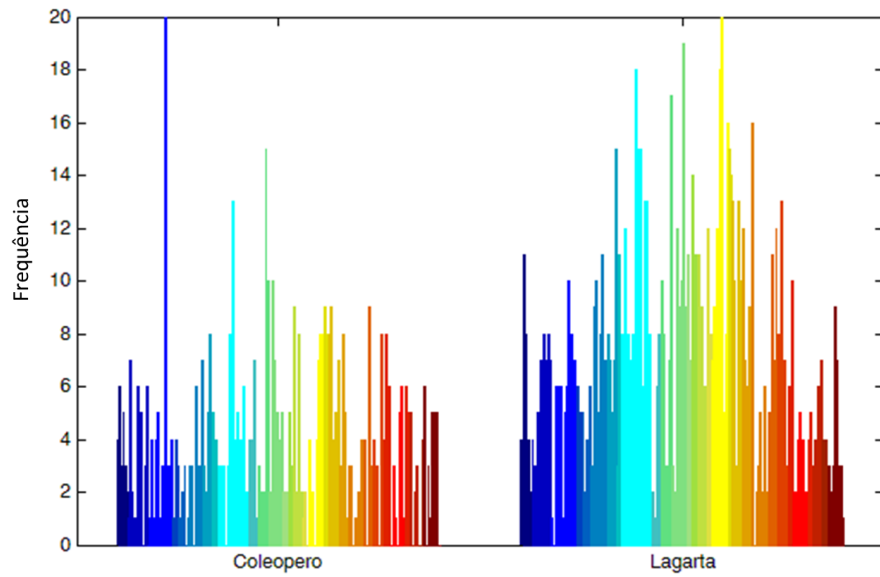


Figura 5.2: Distribuição estatística dos agentes causadores de danos (coleópteros e lagartas) para todas as folhas da base de dados utilizada. O eixo y representa a quantidade de danos das folhas e o eixo x representa as folhas da base de dados, cada folha é relacionada a uma cor.

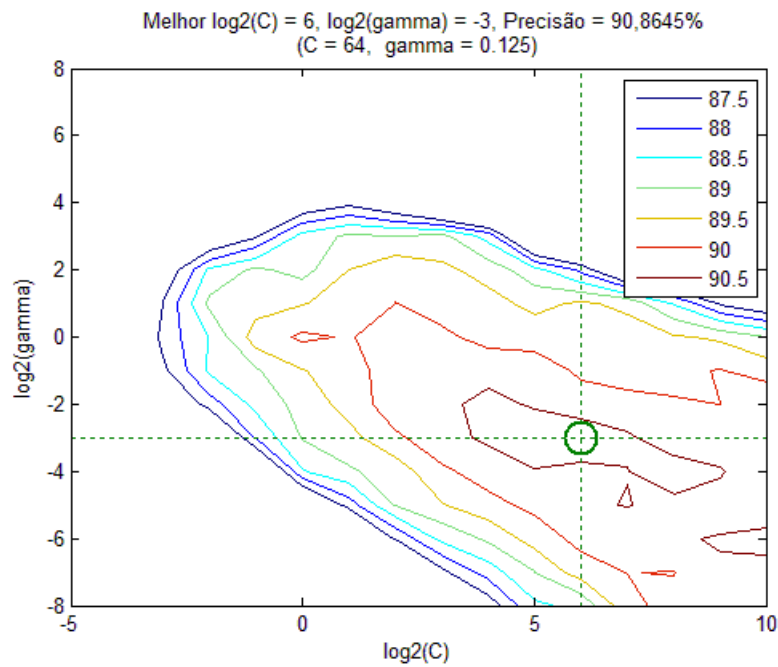


Figura 5.3: Escolha dos melhores valores para C e γ .

de danos da folha. Validação cruzada é um método estatístico para avaliar e comparar algoritmos de aprendizado através da divisão das amostras em dois grupos, um grupo usado para treinamento e outro para teste.

Em nosso caso, a validação cruzada *leave-one-out* separou as amostras da seguinte forma: o grupo de validação possui apenas os danos de um folíolo e o grupo de treinamento possui os danos de todos os outros folíolos da base de dados. Devido à variação de k , as acurácias reportadas pela validação cruzada apresentaram altos valores de desvio padrão, mostrados na Seção 5.3. Além disso, para validar o método proposto, evitamos que sejam reportadas precisões que seriam tendenciosas para determinados conjuntos de treinamento e teste.

5.3 Resultados

Nesta seção serão reportados os resultados do nosso método utilizando os vários descritores que foram propostos. Os resultados estão em função da acurácia de classificação e da sensibilidade das classes. A acurácia reporta a porcentagem dos danos que foram classificados corretamente, isto é, a classificação dos danos que foi igual ao rótulo previamente estabelecido. Já a sensibilidade está relacionada à porcentagem de danos de cada classe que foram classificados corretamente, ou seja, a porcentagem de danos de lagartas que foram classificados como de lagartas e a porcentagem de danos de coleópteros que foram classificados como de coleópteros. Tanto a acurácia quanto as sensibilidades apresentadas são a média das precisões/sensibilidades de todos os folíolos.

5.3.1 Resultados utilizando os descritores baseados em redes complexas

Esta subseção apresentará os resultados obtidos com o método proposto utilizando os descritores baseados em redes complexas, Conectividade e *Joint Degree*.

5.3.1.1 Resultados descritores de Conectividade

Inicialmente testamos os descritores de Conectividade utilizando 2, 5, 10 e 20 descritores. De fato, esses descritores são compostos pelo grau médio e grau máximo de conectividade da rede complexa, então na verdade são 4, 10, 20 e 40 características. Como a rede complexa necessita da evolução dinâmica, fizemos experimentos com quatro valores para limiar inicial T_0 (0,05, 0,10, 0,15 e 0,20) e quatro valores para o limiar final T_Q (0,60, 0,80, 0,90 e 0,95). Com a variação dos limiares, realizamos 16 testes para cada tamanho do conjunto de descritores. Os resultados obtidos estão na Tabela 5.2.

Através da Tabela 5.2, podemos visualizar que utilizando 2 descritores a acurácia ficou em média de 71,4% e as sensibilidades das classes de lagartas e coleópteros foram de 87,2% e 38,6% respectivamente. Já com 5 e 10 descritores, a acurácia ficou na média de 74,7% e as sensibilidades ficaram aproximadamente 87,0% e 48,6% para lagartas e coleópteros. Por fim,

Tabela 5.2: Acurácia para a classificação dos agentes causadores de danos e as sensibilidade para as classes lagarto/*caterpillar* (SenC) e coleóptero/*beetle* (SenB) utilizando os descritores de Conectividade para vários limiares T_0 e T_Q . Os valores entre parenteses significam o desvio padrão para o esquema de validação- cruzada *leave-one-out*.

T_0	T_Q	Redes Complexas - Grau de Conectividade - Média (K) e Grau Máximo (M)											
		Quantidade de T_l utilizados											
		2*			5*			10*			20*		
		Acurácia	SenC	SenB	Acurácia	SenC	SenB	Acurácia	SenC	SenB	Acurácia	SenC	SenB
0,05	0,60	79,2(17,4)	93,1	50,6	79,3(19,0)	89,6	59,7	78,1(16,7)	90,0	53,7	80,5(18,1)	90,0	62,2
0,05	0,80	76,5(19,0)	90,4	48,6	78,9(18,2)	92,4	52,0	78,6(18,3)	91,1	53,3	78,6(17,6)	88,4	59,4
0,05	0,90	77,0(20,2)	91,6	48,5	79,9(18,2)	93,1	53,6	79,8(17,8)	92,2	55,2	79,4(16,8)	91,5	53,7
0,05	0,95	75,4(20,4)	93,9	37,9	78,7(17,4)	89,7	54,1	77,5(18,7)	88,5	55,8	78,7(16,2)	89,9	55,5
0,10	0,60	74,9(19,0)	92,6	38,1	72,8(19,4)	82,9	53,1	77,3(18,2)	88,1	55,8	75,9(18,1)	87,2	54,3
0,10	0,80	73,9(19,1)	90,5	40,3	76,2(19,3)	89,2	50,3	75,2(19,8)	89,4	46,6	75,6(18,6)	90,1	45,7
0,10	0,90	73,0(20,5)	90,8	36,7	75,0(19,5)	87,2	47,9	73,9(19,4)	85,2	52,6	73,1(20,1)	86,2	46,5
0,10	0,95	71,0(20,2)	85,8	40,4	75,6(18,9)	90,1	45,0	72,1(20,5)	82,8	50,5	73,8(18,9)	89,0	40,9
0,15	0,60	74,0(18,2)	89,7	40,3	73,6(19,0)	86,2	46,0	72,3(17,5)	82,8	50,1	75,9(19,5)	86,3	52,1
0,15	0,80	72,2(20,0)	95,6	22,9	74,3(19,6)	86,7	47,9	74,7(19,1)	87,9	47,3	73,1(20,2)	89,2	38,4
0,15	0,90	64,5(20,4)	79,7	33,9	73,7(20,6)	86,6	48,0	72,8(19,6)	86,7	42,9	74,0(20,0)	89,9	40,1
0,15	0,95	66,0(21,1)	83,0	30,7	71,3(20,0)	82,9	48,0	73,5(20,2)	87,2	44,7	72,9(19,2)	88,1	39,9
0,20	0,60	70,3(20,1)	83,3	40,4	72,2(19,6)	84,6	44,5	72,6(20,2)	85,2	44,4	73,1(18,4)	85,8	46,9
0,20	0,80	69,9(20,9)	91,9	22,3	71,4(20,2)	84,2	43,3	72,2(20,1)	87,2	38,9	72,6(19,8)	88,0	38,4
0,20	0,90	62,7(20,6)	70,7	42,5	72,3(20,7)	86,0	41,2	72,2(20,0)	86,1	40,5	73,1(20,3)	87,2	42,0
0,20	0,95	63,4(20,0)	72,8	43,6	70,2(20,7)	80,6	46,5	73,0(20,1)	87,2	42,4	72,4(18,6)	87,9	38,1

utilizando 20 descritores os resultados obtidos foram 75,1% de acurácia e as sensibilidade foram 88,4% para lagartas e 47,1% para coleópteros.

Além desses testes, fizemos experimentos utilizando o grau máximo e o grau médio juntos e separados. Como os resultados anteriores foram semelhantes para as diferentes quantidades de características, escolhemos realizar esse teste utilizando apenas 5 descritores. Os resultados estão na Tabela 5.3.

Os resultados da Tabela 5.3 mostram que mesmo utilizando o grau máximo e o grau médio separados, as acurácias e sensibilidade obtidas são semelhantes à utilização de ambos juntos.

5.3.1.2 Resultados descritores *Joint Degree*

Os testes para os descritores *Joint Degree* foram semelhantes aos de Conectividade, com variação na quantidade de descritores e quatro valores para T_0 e quatro valores para T_Q . Porém, nestes casos, estes descritores são formados pela energia, entropia e *joint degree* média, então, por exemplo, ao utilizar com conjunto com 5 descritores, de fato temos 15 características. Os resultados estão na Tabela 5.4.

Os testes realizados com os descritores *Joint Degree* mostram que o classificador obteve um resultado relevante, ou seja, acurácia superior a 90% e sensibilidade superiores a 80% e equilibradas: perto de 95% para a classe das lagartas e de 85% para a classe dos coleópteros.

Além desses testes, fizemos experimentos para energia, entropia e *joint degree* médio separadamente e combinados dois a dois (Tabela 5.5).

Tabela 5.3: Acurácia para a classificação dos agentes causadores de danos e as sensibilidade para as classes lagarto/*caterpillar* (SenC) e coleóptero/*beetle* (SenB) utilizando os 5 descritores de Conectividade combinados e separados. Os valores entre parenteses significam o desvio padrão para o esquema de validação- cruzada *leave-one-out*.

T_0	T_Q	Redes Complexas - Grau de Conectividade								
		5*								
		K			M			KM		
		Acurácia	SenC	SenB	Acurácia	SenC	SenB	Acurácia	SenC	SenB
0,05	0,60	78,2(17,8)	92,0	48,3	76,0(19,4)	88,7	51,8	78,4(19,8)	87,3	61,9
0,05	0,80	77,6(16,8)	92,0	48,3	78,3(18,2)	93,5	45,8	78,9(18,2)	92,4	52,0
0,05	0,90	77,1(18,3)	94,0	42,4	76,2(18,7)	89,3	50,6	79,9(18,0)	92,6	54,3
0,05	0,95	74,6(18,3)	89,3	45,0	76,9(18,4)	91,3	46,1	79,2(17,8)	92,6	52,0
0,10	0,60	75,1(18,7)	90,3	43,4	70,3(20,1)	83,3	40,3	73,8(19,2)	84,9	51,6
0,10	0,80	75,7(19,0)	91,7	42,7	71,4(20,6)	88,7	35,2	74,1(18,9)	84,2	54,9
0,10	0,90	74,8(18,4)	89,5	42,2	71,7(20,1)	84,0	44,9	75,0(19,5)	87,2	47,9
0,10	0,95	75,4(17,8)	92,8	38,7	70,8(20,9)	82,4	44,2	73,5(18,8)	82,4	54,9
0,15	0,60	75,4(18,6)	87,6	50,2	69,3(20,0)	82,8	39,6	74,5(18,5)	86,9	47,2
0,15	0,80	76,8(17,7)	91,2	45,3	70,3(20,9)	84,8	39,0	74,3(19,6)	86,7	47,9
0,15	0,90	74,6(18,6)	90,0	40,5	71,5(20,6)	83,0	45,5	73,2(20,3)	85,3	48,4
0,15	0,95	74,6(18,4)	90,9	39,2	70,4(21,2)	82,5	41,8	72,6(18,8)	85,1	45,2
0,20	0,60	75,7(17,8)	91,1	39,9	70,1(21,5)	83,6	41,1	73,1(19,5)	87,3	42,1
0,20	0,80	71,9(18,2)	87,5	36,9	71,2(20,7)	84,0	43,5	71,9(20,2)	84,9	42,9
0,20	0,90	73,6(18,9)	91,3	35,1	71,3(20,9)	81,4	48,5	72,5(20,6)	86,0	42,7
0,20	0,95	69,7(20,0)	83,5	38,4	70,0(20,6)	80,1	46,8	70,2(20,7)	80,6	46,5

Tabela 5.4: Acurácia para a classificação dos agentes causadores de danos e as sensibilidade para as classes Lagarto/*Caterpillar* (SenC) e coleóptero/*beetle* (SenB) utilizando descritores *Joint Degree* (Energia, Entropia e *Joint Degree* médio). Os valores entre parenteses significam o desvio padrão para o esquema de validação- cruzada *leave-one-out*.

T_0	T_Q	Redes Complexas - Probabilidade Joint Degree											
		Quantidade de T_i utilizados											
		2*			5*			10*			20*		
		Acurácia	SenC	SenB	Acurácia	SenC	SenB	Acurácia	SenC	SenB	Acurácia	SenC	SenB
0,05	0,60	90,4(13,8)	90,5	91,5	92,2(11,7)	95,1	87,4	92,1(11,6)	95,7	84,3	92,3(10,9)	95,5	85,7
0,05	0,80	90,1(15,1)	89,9	92,3	92,5(11,0)	95,3	87,3	92,1(11,6)	95,5	85,6	91,9(12,1)	95,5	84,9
0,05	0,90	90,8(13,6)	91,2	91,3	92,1(12,0)	95,3	86,1	92,1(11,9)	95,1	84,7	91,3(13,5)	94,7	84,4
0,05	0,95	90,3(14,1)	90,1	92,0	92,2(11,6)	95,2	87,6	91,6(13,5)	95,1	84,7	92,4(11,6)	96,2	84,2
0,10	0,60	90,3(15,1)	92,8	86,2	92,1(11,8)	96,1	84,2	92,1(11,8)	96,0	83,3	92,2(11,6)	95,7	85,2
0,10	0,80	91,4(11,6)	94,1	86,4	92,0(12,0)	95,1	86,7	91,7(13,4)	94,7	86,4	92,0(11,7)	95,8	84,0
0,10	0,90	90,8(13,7)	94,4	85,0	91,6(13,6)	94,6	87,0	91,9(12,0)	95,4	84,9	92,3(11,6)	95,6	85,4
0,10	0,95	90,3(14,4)	92,4	85,8	92,6(11,3)	96,1	86,0	92,3(11,6)	95,5	85,2	92,8(10,8)	95,4	86,2
0,15	0,60	91,1(13,5)	94,2	84,4	91,6(11,6)	95,1	84,0	91,9(11,8)	95,5	83,6	91,9(11,7)	95,4	84,5
0,15	0,80	91,3(13,6)	94,0	85,7	92,1(11,4)	95,9	83,4	92,1(11,6)	95,7	84,7	91,9(11,6)	95,4	84,2
0,15	0,90	90,9(15,3)	92,9	86,9	92,0(11,7)	95,8	84,3	92,0(11,8)	96,0	83,3	91,4(13,0)	94,7	83,7
0,15	0,95	91,3(13,6)	93,6	87,3	92,6(11,2)	96,2	84,8	92,0(11,9)	95,5	84,2	91,9(11,6)	95,8	83,1
0,20	0,60	91,9(11,6)	94,7	86,2	91,8(11,6)	95,8	83,5	91,5(11,6)	95,7	82,4	91,7(11,9)	96,1	82,0
0,20	0,80	91,9(11,7)	94,5	86,4	91,8(11,6)	95,3	84,4	91,9(11,5)	95,6	84,0	91,3(11,4)	94,7	83,6
0,20	0,90	92,2(11,6)	95,6	85,3	91,8(11,9)	95,8	83,0	92,0(11,7)	95,5	84,5	91,6(12,3)	95,3	84,4
0,20	0,95	92,3(11,7)	95,4	85,8	92,2(11,5)	95,8	84,4	91,5(13,5)	95,0	83,8	92,1(11,6)	95,4	84,5

Tabela 5.5: Acurácia para a classificação dos agentes causadores de danos e as sensibilidade para as classes Lagarto/*Caterpillar* (SenC) e coleóptero/*beetle* (SenB) utilizando descritores 5 *Joint Degree* separados e combinados de dois a dois. Os valores entre parenteses significam o desvio padrão para o esquema de validação- cruzada *leave-one-out*.

T_0	T_Q	Redes Complexas - Probabilidade Joint Degree - Energia (E), Entropia (H), e Probabilidade Média (P)																	
		5*																	
		E			H			P			EH			EP			HP		
		Acurácia	SenC	SenB	Acurácia	SenC	SenB	Acurácia	SenC	SenB	Acurácia	SenC	SenB	Acurácia	SenC	SenB	Acurácia	SenC	SenB
0,05	0,60	84,1(16,2)	91,8	67,7	89,6(15,3)	91,1	87,1	85,8(16,4)	85,6	87,0	92,6(11,3)	95,1	88,0	92,0(11,6)	95,7	84,5	91,3(13,6)	94,2	86,5
0,05	0,80	84,7(13,9)	93,3	64,6	89,6(14,1)	89,5	90,6	88,4(14,3)	92,0	80,1	92,5(10,8)	94,7	88,1	91,4(11,2)	94,3	84,5	91,7(11,5)	94,6	85,7
0,05	0,90	86,4(12,7)	92,5	71,1	90,9(13,7)	91,1	91,6	89,6(13,8)	93,8	81,0	92,2(11,0)	94,8	87,0	91,3(13,0)	94,8	84,2	91,9(12,0)	95,3	85,0
0,05	0,95	87,1(14,3)	91,2	77,6	92,0(13,1)	93,1	90,4	89,4(12,9)	93,5	79,4	92,3(11,6)	94,7	88,5	91,7(12,0)	94,7	85,9	91,9(12,1)	94,6	87,6
0,10	0,60	79,4(17,9)	80,0	77,0	90,2(15,5)	92,3	86,1	84,0(16,4)	81,3	89,4	91,2(13,7)	94,0	85,6	91,4(12,9)	95,3	83,8	91,3(13,7)	94,9	84,4
0,10	0,80	82,1(17,5)	90,9	62,6	91,0(13,1)	93,2	87,0	89,6(13,8)	93,3	81,3	92,1(11,2)	94,6	87,1	91,1(13,4)	94,9	83,8	92,4(11,7)	95,0	88,0
0,10	0,90	83,0(16,9)	90,6	66,3	91,1(13,6)	93,3	87,8	89,1(13,8)	93,6	78,7	91,4(12,2)	93,9	87,1	91,1(13,9)	94,5	85,1	91,8(13,6)	94,7	87,0
0,10	0,95	86,2(13,8)	90,4	74,3	91,6(13,0)	94,0	87,1	89,2(13,9)	94,0	78,7	91,9(12,0)	94,8	86,8	92,1(11,6)	95,8	84,4	92,1(13,3)	95,1	87,1
0,15	0,60	83,5(15,5)	87,4	72,3	89,8(13,7)	94,2	80,4	85,4(16,2)	85,5	84,2	90,6(12,3)	95,0	81,1	91,3(12,7)	95,6	80,7	92,2(11,5)	95,4	85,0
0,15	0,80	81,0(17,3)	85,7	70,4	89,8(12,4)	94,1	79,7	90,0(12,3)	94,0	79,5	90,7(11,9)	94,5	81,7	91,2(11,8)	95,3	81,3	92,2(11,4)	95,9	83,6
0,15	0,90	82,0(17,6)	89,1	66,9	91,3(12,3)	93,8	86,4	89,1(13,8)	94,1	76,7	90,9(13,7)	94,2	85,2	91,6(11,4)	96,3	79,5	91,4(13,6)	95,2	84,0
0,15	0,95	85,6(14,9)	88,1	77,7	92,1(11,3)	95,1	86,0	87,0(14,4)	88,1	82,9	92,1(13,0)	94,5	87,9	92,1(11,5)	96,0	82,4	92,7(11,3)	96,1	86,1
0,20	0,60	81,6(16,8)	83,5	76,2	84,7(16,7)	91,0	69,5	85,8(15,9)	86,8	83,1	90,5(12,0)	95,6	78,8	90,8(11,5)	95,7	79,7	92,0(11,6)	95,6	84,3
0,20	0,80	82,0(17,0)	88,6	67,3	87,2(14,3)	92,5	75,1	88,7(14,5)	93,0	78,4	90,5(13,5)	94,7	81,1	91,3(11,3)	95,0	82,5	92,0(11,7)	95,5	84,5
0,20	0,90	82,5(16,2)	85,9	73,7	89,8(13,7)	92,5	85,2	89,5(12,3)	95,1	75,7	90,8(13,7)	94,4	83,1	91,5(11,2)	95,3	82,1	92,2(11,5)	95,3	85,3
0,20	0,95	85,2(15,0)	89,3	75,3	91,7(11,3)	93,4	86,9	90,4(11,6)	94,4	80,1	91,8(11,8)	94,5	85,5	91,8(11,8)	94,9	84,6	92,2(11,6)	95,6	85,2

A Tabela 5.5 mostra que utilizar os descritores de energia e probabilidade média separados, os resultados não resultam em acurácias e sensibilidade tão significantes quanto os resultados obtidos com os três juntos (Tabela 5.4). Alguns resultados utilizando apenas a entropia (por exemplo com $T_0 = 0,05$ e $T_Q = 0,09$), foram semelhantes aos resultados obtidos com os três descritores juntos (EHP). Nos testes que em os descritores aparecem combinados dois a dois os resultados são tão relevantes quanto utilizados a energia, entropia e probabilidade média juntos.

5.3.2 Resultados utilizando os descritores de Fourier

Realizamos experimentos com diferentes quantidades de descritores de Fourier (2, 3, 5, 10, 15, 20, 25, 30, 40, 50) para avaliar a representatividade dessas características, ou seja, avaliar se poucos descritores são suficientes para se obter uma alta taxa de acurácia na classificação ou se a acurácia só é alta com a utilização de muitos descritores. A Tabela 5.6 apresenta os resultados obtidos.

Tabela 5.6: Acurácia para a classificação dos agentes causadores de danos e as sensibilidade para as classes lagarta/*caterpillar* (SenC) e coleóptero/*beetle* (SenB) utilizando os descritores de Fourier. Foram utilizados os 2, 3, 5, 10, 15, 20, 25, 30, 40 e 50 primeiros descritores. Os valores entre parenteses significam o desvio padrão para o esquema de validação-cruzada *leave-one-out*.

Descritores de Fourier																			
Qnt	Acurácia	SenC	SenB	Qnt	Acurácia	SenB	SenC	Qnt	Acurácia	SenC	SenB	Qnt	Acurácia	SenC	SenB	Qnt	Acurácia	SenC	SenB
2	87,6(15,6)	93,7	76,1	5	88,4(15,4)	94,6	76,4	15	88,9(13,6)	94,9	76,1	25	89,4(12,3)	93,4	80,1	40	88,8(13,0)	90,9	82,8
3	87,6(15,0)	93,4	76,1	10	89,2(13,7)	95,5	76,1	20	89,1(13,0)	93,8	77,8	30	88,8(13,9)	92,9	79,6	50	90,0(13,5)	93,8	80,5

Ao analisar a tabela de resultados, é possível visualizar que uma grande variação na quantidade de descritores não causou grandes variações na acurácia e sensibilidade de classificação

(Cálculos estatísticos dessa variação serão apresentados na Seção 5.4). Por exemplo, com os primeiros 10 descritores de Fourier, a acurácia foi de 89%, enquanto com os 50 primeiros descritores a acurácia foi de 90%, uma mudança pouco significativa. Isso pode ocorrer pois, segundo [Gonzalez e Woods \(2010\)](#), os primeiros descritores (coeficientes de Fourier com menor frequência) devem ser utilizados como características pois possuem informações mais relevantes da representação do contorno. Dessa forma, pegar muitos ou poucos descritores não causa grandes variações no resultado da classificação, o importante é utilizar sempre os primeiros descritores.

As características extraídas a partir da transformada de Fourier apresentaram acurácia de classificação de aproximadamente 89%. A sensibilidade para a classe de lagarta foi superior a 90%, enquanto para a classe de coleóptero foi aproximadamente 80%. Isto é, os danos causados por lagartas foram classificados corretamente pelo SVM em uma taxa maior do que os danos causados por coleópteros.

5.3.3 Resultados utilizando os descritores *Wavelet*

Os experimentos com os descritores *Wavelet* foram realizados para três principais bases de função *wavelet*: Haar, Daubechies 2 e Daubechies 3. Escolhemos essas funções de base pois são as mais utilizadas para obter descritores de características como no nosso caso. Além disso, diferentemente dos descritores de Fourier, utilizamos os descritores *Wavelet* de maior valor em módulo, pois empiricamente apresentaram resultados mais significativos. Também utilizamos diferentes quantidades desses descritores (10, 20, 30, 40 e 50), porém, essa quantidade foi articulada de acordo com uma porcentagem. Isto é, ao escolher, por exemplo, 10 descritores *Wavelet*, testamos a classificação com 25, 50, 75, 90 e 100% desses descritores. A Tabela 5.7 apresenta os resultados obtidos.

Na literatura ([Osowski e Nghia, 2002](#)), apenas os maiores descritores *Wavelet* são utilizados. Porém, através de testes, percebemos que dado um conjunto com 10 descritores, por exemplo, utilizar somente os maiores não é suficiente para obtermos uma acurácia aceitável. Dessa forma, incluímos a parte de escolher uma porcentagem desse conjunto. Nos resultados apresentados na Tabela 5.7, é possível visualizar que os melhores resultados foram obtidos utilizando entre 90 e 100% do conjunto de descritores original.

Segundo nossos experimentos, não importa qual a quantidade de características e sim a porcentagem delas que é utilizada. Isso mostra que, de fato, ao escolher um conjunto dos maiores descritores, é necessário utilizar todo esse conjunto e não apenas os descritores mais significativos do mesmo. Também é importante a ordenação do conjunto. Essas conclusões são válidas para o nosso estudo.

Em relação às três funções de base utilizadas, os resultados não apresentam informações para discernir se uma função é melhor que a outra. Todas apresentaram resultados semelhantes. Utilizando entre 10, 25 e 50% do conjunto de descritores, a acurácia de classificação ficou

Tabela 5.7: Acurácia para a classificação dos agentes causadores de danos e as sensibilidade para as classes lagarta/*caterpillar* (SenC) e coleóptero/*beetle* (SenB) utilizando os descritores *Wavelet* com as funções de base Haar, Db2 e Db3. Os valores entre parenteses significam o desvio padrão para o esquema de validação- cruzada *leave-one-out*.

Base Tam		Transformada Wavelet											
		Percentual											
		25%			50%			75%			90%		
		Acurácia	SenC	SenB	Acurácia	SenC	SenB	Acurácia	SenC	SenB	Acurácia	SenC	SenB
Haar	10	60,9(22,1)	78,1	26,2	67,1(21,6)	91,1	17,1	87,8(13,9)	94,2	74,9	87,1(15,6)	92,6	76,7
	20	56,3(21,5)	64,6	34,5	65,3(22,0)	85,2	23,4	80,1(18,3)	92,5	54,5	89,3(12,9)	90,7	86,9
	30	71,8(19,6)	84,1	44,2	73,2(19,3)	83,6	50,5	89,9(12,9)	92,6	84,4	90,2(13,0)	93,2	83,5
	40	65,0(21,5)	80,4	31,8	67,4(20,8)	82,3	36,7	79,4(17,9)	91,7	51,3	90,2(12,0)	94,0	81,7
	50	72,5(19,5)	85,0	44,9	73,5(19,0)	84,1	51,7	90,4(12,0)	93,5	84,5	89,6(12,3)	92,5	84,9
Db2	10	62,7(19,6)	84,6	17,1	65,4(20,6)	77,3	43,4	76,1(18,0)	80,5	64,7	77,9(17,1)	82,0	67,7
	20	60,0(21,2)	69,9	37,4	61,9(22,1)	81,3	22,8	89,4(12,1)	89,2	90,4	90,3(11,5)	90,7	89,5
	30	70,2(20,0)	87,1	34,6	73,5(18,8)	85,2	46,7	88,7(12,6)	88,8	89,3	90,4(11,5)	91,8	88,1
	40	68,5(22,4)	93,3	16,0	66,6(21,4)	89,2	18,5	82,5(16,6)	94,1	57,5	88,2(13,7)	91,6	80,6
	50	71,0(19,7)	83,9	42,1	74,8(19,0)	85,1	51,5	90,3(11,7)	93,8	82,2	89,7(12,2)	94,6	79,4
Db3	10	64,8(22,7)	85,8	16,4	64,9(20,9)	77,5	40,6	73,2(18,8)	81,5	52,0	82,1(15,9)	83,9	76,6
	20	61,4(20,6)	76,1	29,2	68,3(19,3)	80,3	38,9	84,8(14,9)	92,6	69,2	86,6(14,4)	93,7	73,3
	30	61,7(20,0)	75,6	34,2	72,7(17,9)	85,9	45,2	89,8(12,4)	92,9	84,1	90,3(12,0)	93,9	83,5
	40	67,5(21,5)	87,5	24,5	69,2(20,2)	90,8	24,8	88,8(12,9)	95,5	75,3	88,8(12,9)	95,5	75,3
	50	68,9(20,7)	87,2	29,4	72,5(19,2)	84,6	46,5	89,6(13,2)	89,1	91,8	90,2(12,3)	93,1	85,5

entre 60 e 70% para todos os tamanhos de conjuntos. Para esse tipo de teste, a sensibilidade da classe de coleópteros foi muito baixa, chegando a 0, o que significa que o SVM classificou todos os danos como de lagarta. Esses resultados mostram que é necessário utilizar quase todo o vetor de descritores para obter resultados efetivos.

Escolhendo entre 75, 90 e 100% dos descritores, a acurácia variou entre 80 e 90%. Nesse caso, a sensibilidade se comportou semelhante aos casos de uso dos descritores de Fourier, na média de 90% para a classe de lagarta e aproximadamente 80% para a classe de coleópteros.

5.3.4 Resultados utilizando os descritores de Zernike

Os descritores de Zernike são obtidos através do cálculo dos momentos de Zernike. É possível obter vários momentos de Zernike variando a ordem/grau desses momentos. Para testar a eficiência desses descritores, realizamos experimentos com os momentos de ordem 1 até ordem 18. Os momentos de ordem 18 geram uma quantidade grande de descritores, o que justifica ter sido o limite superior dos testes. Os resultados obtidos estão na Tabela 5.8.

É possível ver na tabela que mesmo variando a ordem dos momentos de Zernike, não houve grandes mudanças em relação à acurácia de classificação. Esse tipo de descritor apresentou uma taxa de acurácia de aproximadamente 70%. A média de sensibilidade da classe das lagartas foi de 80% enquanto a da classe dos coleópteros foi de 50%.

Tabela 5.8: Acurácia para a classificação dos agentes causadores de danos e as sensibilidade para as classes lagarto/*caterpillar* (SenC) e coleóptero/*beetle* (SenB) utilizando os descritores de Zernike de ordem variando de 1 a 18. Os valores entre parenteses significam o desvio padrão para o esquema de validação- cruzada *leave-one-out*.

Momentos de Zernike											
Grau	Acurácia	SenC	SenB	Grau	Acurácia	SenC	SenB	Grau	Acurácia	SenC	SenB
1	68,2(22,8)	98,6	2,9	7	74,0(19,2)	87,9	44,3	13	73,0(21,1)	86,5	46,2
2	70,2(21,0)	82,9	42,9	8	74,1(19,4)	88,2	43,8	14	75,3(19,0)	86,8	51,5
3	71,6(20,3)	86,6	40,4	9	73,0(20,8)	82,8	52,6	15	74,8(20,4)	87,3	49,4
4	70,8(20,3)	81,8	47,0	10	74,1(18,4)	85,2	49,9	16	72,6(20,8)	79,5	57,4
5	73,9(20,0)	88,8	42,9	11	74,4(18,4)	85,5	50,3	17	74,5(19,7)	82,0	56,0
6	73,7(19,7)	87,9	44,3	12	73,4(19,5)	85,1	48,4	18	75,9(18,5)	85,7	54,3

5.4 Grau de “Robustez” das Características

Em nosso trabalho, uma característica é robusta quando, mesmo sofrendo variações nos tamanhos das amostras utilizadas para classificação ou variações nos limiares que constituem as características, elas apresentam resultados aproximados. Essa medida é importante pois, como nosso objetivo é escolher o melhor descritor de características entre todos apresentados no Capítulo 3, o descritor escolhido deve apresentar acurácia e sensibilidade altas, além de ser robusto, dessa forma não serão necessários muitos descritores para representar a característica.

Para calcular o quão robusta é uma característica, utilizamos um teste de hipótese estatístico combinando de dois a dois todos os resultados obtidos nos experimentos de cada característica. Dessa forma podemos concluir se um resultado é de fato parecido/próximo a outro e então se a característica é realmente robusta.

O teste de hipótese escolhido foi o *teste t*, que usa a estatística para rejeitar ou não uma hipótese nula. Esse teste utiliza os dados da amostra para calcular a estatística *t* e depois compará-la com a distribuição *t* para identificar a probabilidade de se ter obtido o resultado observado, caso a hipótese nula seja verdadeira (Montgomery e Runger, 2010). Em nosso caso, o teste foi feito em pares, e a hipótese nula é que não existe diferença estatística entre dois resultados dos experimentos realizados. Como os resultados/amostras são dependentes, então este teste é apropriado.

O *teste t* é dado pela diferença entre as médias das amostras, isto é, a quantidade de resultados similares menos a quantidade de resultados diferentes. Além disso, existe um intervalo de confiança que expressa a ideia de que existe um determinado nível de confiança em que a média se encontra naquele intervalo. O limite de aceitação desse intervalo é dado por α . Se $\alpha = 5\%$, o intervalo de confiança é $(1 - \alpha) = 95\%$. Quanto maior o valor de α , maior o grau de exigência para um valor ficar dentro do intervalo de confiança, ou seja, em nosso caso, quanto maior o valor de α , mais difícil para dois resultados serem similares (Montgomery e Runger, 2010).

Para realizar os testes, consideramos α com os valores 0,01, 0,05, 0,1 e 0,2, ou seja, testamos os intervalos de confiança de 99%, 95%, 90% e 80%. Para os descritores de Conectividade

e *Joint Degree*, testamos separadamente utilizando 2, 5, 10, 20 descritores e também testamos com todas essas quantidades de descritores juntas. Para os descritores *Wavelet* testamos para os três tipos de *Wavelet* separadamente. A Tabela 5.9 apresenta os resultados obtidos.

Tabela 5.9: Teste-t Emparelhado: Grau de “Robustez” das Características em Porcentagem.

α (alfa)	0,01	0,05	0,1	0,2
Conectividade (KM) - 2*	41,6	40,0	17,5	2,5
Conectividade (KM) - 5*	65,0	47,5	41,6	33,3
Conectividade (KM) - 10*	65,0	53,3	44,1	35,8
Conectividade (KM) - 20*	72,5	64,1	60,8	43,3
Conectividade (KM)	66,7	54,6	39,3	26,3
Conectividade Média (K) - 5*	48,3	35,0	27,5	21,6
Conectividade Grau Máximo (M) - 5*	75,8	57,5	47,5	34,1
<i>Joint Degree</i> (EHP) - 2*	85,8	67,5	55,0	38,3
<i>Joint Degree</i> (EHP) - 5*	100,0	97,5	94,1	83,3
<i>Joint Degree</i> (EHP) - 10*	100,0	100,0	99,1	95,0
<i>Joint Degree</i> (EHP) - 20*	100,0	96,6	90,8	77,5
<i>Joint Degree</i> (EHP)	95,2	84,3	78,0	68,2
<i>Joint Degree</i> - Energia (E) - 5*	81,6	67,5	61,6	42,5
<i>Joint Degree</i> - Entropia (H) - 5*	44,1	35,0	27,5	21,6
<i>Joint Degree</i> - Prob. Média (P) - 5*	93,3	73,3	65,0	56,6
<i>Joint Degree</i> - Energia, Entropia (EH) - 5*	37,5	25,0	21,6	13,3
<i>Joint Degree</i> - Energia, Prob. Média (EP) - 5*	93,3	80,8	70,0	55,8
<i>Joint Degree</i> - Entropia, Prob. Média (HP) - 5*	95,0	86,6	81,6	71,6
Fourier	97,7	88,8	77,7	71,7
Zernike	66,0	54,2	47,7	42,4
Wavelet - Db2	17,9	14,9	13,1	10,3
Wavelet - Db3	19,0	14,7	13,3	9,6
Wavelet - Haar	20,4	18,6	16,5	12,6

Os resultados da Tabela 5.9 mostram que o descritor *Joint Degree* utilizando vetores de tamanho 5, 10, 20 é o mais robusto segundo nosso critério. O segundo descritor mais robusto foi o de *Fourier*, com “robustez” de 97% para $\alpha = 0,01$. Os próximos descritores com melhores resultados foram as combinações de Entropia e Probabilidade Média (95%, $\alpha = 0,01$), Energia e Probabilidade Média (93,3%, $\alpha = 0,01$) e Probabilidade Média sozinha (93,3%, $\alpha = 0,01$). O descritor *Conectividade* apresentou “robustez” média de 66,7% com $\alpha = 0,01$, seguido de Zernike com 66% com $\alpha = 0,01$ e por último *Wavelet*, com “robustez” 17,9%, 19% e 20,4% com $\alpha = 0,01$, para os três tipos de *Wavelet* testados.

5.5 Análise Geral dos Resultados

Comparando os dados das tabelas apresentadas é possível concluir que a sensibilidade para a classe das lagartas foi maior do que a da classe dos coleópteros para quase todos os casos. Isso pode ser explicado devido ao desbalanceamento das classes em nossa base de amostra, ou seja, a quantidade de danos causados por lagartas é maior do que a quantidade de danos causados por coleópteros.

Analisando o resultado de todos os descritores utilizados, os que obtiveram piores resultados foram Conectividade e Zernike, apresentando aproximadamente 70% de acurácia, com a sensibilidade da classe de lagartas entre 80 e 90% e da classe de coleópteros entre 40 e 50%. Esses descritores não foram robustos para as variações de parâmetros realizadas, variações dos limiares no caso dos descritores de Conectividade, e variação do grau dos momentos no casos dos descritores de Zernike. Ainda, com esses descritores o método apresentou acurácia mais baixa em relação com os outros descritores propostos.

Os descritores *Wavelet* apresentaram acurácia entre 80 e 90%, o que é maior que os descritores de Conectividade e Zernike, porém é necessário grande quantidade de descritores para obter estes resultados. Por este motivo, dizemos que este tipo de descritor não é robusto mesmo apresentando resultados satisfatórios. Com relação às sensibilidades para as duas classes, os descritores *Wavelet* apresentaram resultados superiores aos dos descritores de Conectividade e Zernike.

Os outros dois descritores, Fourier e *Joint Degree* apresentaram os melhores resultados. As características de Fourier obtiveram média de 90% e são robustas. Mesmo com poucos descritores os resultados foram semelhantes. Além disso, a sensibilidade ficou entre 90% e 80% para lagartas e coleópteros, respectivamente. As características de *Joint Degree* apresentaram acurácia superior a 90% e sensibilidade média de 95% para lagartas e 85% para coleópteros. Esses descritores também são robustos. Mesmo com a variação dos limiares da evolução dinâmica e variação da quantidade de descritores utilizados os resultados foram muito próximos.

A Tabela 5.10 apresenta um resumo dos resultados obtidos para os diferentes descritores. Como vários experimentos foram realizados, os valores apresentados nessa tabela são porcentagens aproximadas.

Tabela 5.10: Resumo dos resultados obtidos para os diferentes descritores

Descritores	Acurácia	SenC	SecB	“Robustez Média” ($\alpha = 0,01$)
<i>Joint Degree</i>	92%	95%	85%	95%
Fourier	89%	93%	78%	97%
Conectividade	73%	87%	45%	62%
Zernike	73%	86%	45%	66%
<i>Wavelet</i>	65%	78%	36%	19%

5.6 Exemplo Ilustrativo

As imagens da Figura 5.4 apresentam exemplos ilustrativos da classificação do folíolo da Figura 5.4a realizada pelo SVM utilizando os cinco descritores apresentados. Os danos coloridos de vermelho são danos de lagartas classificados corretamente; os danos em azul são os de coleópteros classificados corretamente; os danos em amarelo são de lagarta mas foram classificados como de coleópteros; finalmente, os danos em ciano são de coleópteros classificados como de lagarta. Observe que somente quando foi usado o descritor de Fourier ocorreu de danos de coleópteros serem classificados como de lagarta, representados pela cor ciano.




Figura 5.4: Exemplo ilustrativo da classificação do SVM para os cinco descritores utilizados. Os danos coloridos de vermelho são danos de lagartas classificados corretamente; os danos em azul são os de coleópteros classificados corretamente; os danos em amarelo são de lagarta que foram classificados como de coleópteros; os danos em ciano são de coleópteros classificados como de lagarta.

Capítulo 6

Conclusões e Trabalhos Futuros

Na literatura atual, existem técnicas de classificação automática relacionadas a cultivares e também às suas patologias, porém não se encontram métodos acerca da caracterização das pragas que agem sobre as culturas. Nesse trabalho, foi proposto, implementado, testado e validado um método para caracterização automática dos agentes causadores de danos em folíolos de soja. Os principais agentes são os coleópteros e as lagartas e podem ser caracterizados de acordo com o formato de seus danos.

Este método é dividido em três etapas principais: (1) Pré-processamento; (2) Extração de características; e (3) Classificação. A primeira etapa consiste na filtragem da imagem do folíolo (Nazaré-Jr et al., 2010) e na extração do contorno do dano a partir da imagem do folíolo. A próxima etapa, Extração de Características, utiliza descritores de características para representar a informação visual contida nas imagens dos danos. Utilizamos os descritores baseados em redes complexas (Souza et al., 2011b) e também os descritores de Fourier, Wavelet e Zernike (Souza et al., 2011a). Tanto os descritores de redes complexas quanto os descritores de Fourier e Wavelet utilizam o contorno do dano para extração das características. Já os descritores de Zernike utilizam a área do dano. A terceira etapa consiste na classificação das características extraídas. Para isso, escolhemos o algoritmo classificador *Support Vector Machines* (SVM), composto por uma fase de treinamento e outra de testes. O treinamento foi realizado por um especialista em uma base de dados com 178 amostras de folíolos de soja, através de uma plataforma web implementada para essa tarefa.

Os experimentos realizados mostram que o método proposto usando os descritores *joint degree* apresentou o melhor resultado em comparação com os outros descritores implementados, com precisão superior a 90%, levando-se em consideração também um equilíbrio entre a sensibilidade das classes coleóptero e lagarta. Esse método é robusto no sentido de que grandes variações nos limiares não modificam estatisticamente a precisão da classificação. Utilizando os descritores de Fourier os resultados também foram satisfatórios, média de 90%. Além disso o cálculo desses descritores necessita de apenas um parâmetro e também é robusto. Utilizando poucos ou muitos descritores de Fourier, a precisão não sofreu modificações relevantes.

O método utilizando os descritores *Wavelet* apresentaram resultados satisfatórios em relação à precisão, porém é necessário um grande número de descritores para obter esses resultados, diferentemente dos descritores citados anteriormente que com poucas características a precisão foi relevante. A utilização dos descritores de Conectividade e de Zernike apresentaram resultados menos significantes, média de 70% de precisão de classificação.

Por fim, os resultados em relação à sensibilidade das classes mostraram que a classe das lagartas foi classificada corretamente mais vezes em relação à classificação da classe dos coleópteros. Isso corrobora o fato de que há um desbalanceamento entre as classes, mais danos são causados por lagartas do que por coleópteros. Apesar desse desbalanceamento, o método proposto apresentou resultados relevantes.

Como trabalhos futuros iremos implementar outros algoritmos de classificação, como Redes Neuroniais, *k-Nearest Neighbor* (k-NN) e *Optimal Path-Forest* (Papa et al., 2012) para efeito de comparação.

Além disso, para classificação dos folíolos a respeito dos agentes danificadores, é possível classificar o dano apenas por lagartas, principalmente por lagartas, principalmente por coleópteros, apenas coleópteros e ambos, onde o termo “apenas” é empregado se mais do que 90% dos danos são causados por apenas um agentes; “ambos” é utilizado quando metade dos danos (*e.g.*, $50\% \pm 10\%$) são causados por ambos agentes, e “principalmente” caso contrário. Nesse caso, a área (Nazaré-Jr et al., 2010) de cada dano é levada em consideração para computar o dano total de cada agente. Então, como trabalho futuro, propõe-se analisar o impacto da classificação do dano com a sua área na classificação de todo o folíolo.

Referências Bibliográficas

- Antiqueira, L.; Nunes, M. G. V.; Oliveira, O. N. e Costa, L. F. (2007). Strong correlations between text quality and complex networks features. *Physica A*, 373(1):811–820. [10](#)
- Backes, A. R.; Casanova, D. e Bruno, O. M. (2009). A complex network-based approach for boundary shape analysis. *Pattern Recognition*, 42(1):54–67. [3](#), [7](#), [10](#), [11](#), [13](#)
- Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer, 2ª edição. [22](#)
- Briggs, W. L. e Henson, V. E. (1995). *The DFT: an owner's manual for the discrete Fourier transform*. Siam, 1ª edição. [3](#), [16](#)
- Camargo, A. e Smith, J. S. (2009a). Image pattern classification for the identification of disease causing agents in plants. *Computers and Electronics in Agriculture*, 66(2):121–125. [6](#)
- Camargo, A. e Smith, J. S. (2009b). An image-processing based algorithm to automatically identify plant disease visual symptoms. *Biosystems Engineering*, 102(1):9–21. [6](#), [7](#)
- Chalumeau, T.; Costa, L. F.; Laligant, O. e Meriaudeau, F. (2006). Texture discrimination using hierarchical complex networks. In *International Conference on Signal-Image Technology and Internet-Based Systems*, pp. 543–550. [10](#)
- Chang, C.-C. e Lin, C.-J. (2011). Libsvm: A library for support vector machines. *ACM Transactions on Intelligent Systems and Technology*, 2(3):27:1–27:27.
- Cortes, C. e Vapnik, V. (1995). Support-vector networks. *Machine Learning*, 20(3):273–297. [3](#), [21](#)
- de Moura, M. F.; Picanço, M. C.; Ézio Marques da Silva; Guedes, R. N. C. e Pereira, J. L. (2003). Sampling plan for B-biotype of Bemisia tabaci in cucumber crop. *Pesquisa Agropecuária Brasileira*, 38(12):1357–1363. [1](#)
- Duda, R. O.; Hart, P. E. e Stork, D. G. (2001). *Pattern Classification*. Wiley-Interscience, 2ª edição. [21](#)

- Gonzalez, R. C. e Woods, R. E. (2007). *Digital Image Processing*. Prentice Hall, 3ª edição. 10
- Gonzalez, R. C. e Woods, R. E. (2010). *Processamento Digital de Imagens*. Prentice Hall, 3ª edição. 14, 16
- Gonzalez, R. C.; Woods, R. E. e Eddins, S. L. (2004). *Digital Image Processing Using MATLAB*. Prentice Hall. 7, 9
- Hsu, C.-W.; Chang, C.-C. e Lin, C.-J. (2010). A practical guide to support vector classification. Practical guide, Department of Computer Science, National Taiwan University. 23, 24
- Hu, M.-K. (1962). Visual pattern recognition by moment invariants. *IRE Transactions on Information Theory*, 8(2):179–187. 20
- Jr, D. G. S.; Pinto, F. A. C.; Queiroz, D. M. e Viana, P. A. (2003). Fall armyworm damaged maize plant. *Biosystems Engineering*, 85(4):449–454. 6
- Kim, W.-Y. e Kim, Y.-S. (2000). A region-based shape descriptor using zernike moments. *Signal Processing: Image Communication*, 16(1-2):95–102. 5
- Ling, H. e Jacobs, D. W. (2007). Shape classification using the inner-distance. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 29(2):286–299. 6
- Mallat, S. G. (1989). A theory for multiresolution signal decomposition: The wavelet representation. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 11(7):674–693. 3
- Mallat, S. G. (2004). Estudo comparativo entre funções wavelet e suas diferentes aplicações em reconhecimento de padrões epileptogênicos em eletroencefalograma. *Revista Brasileira de Engenharia Biomédica*, 20(2-3):49–59. 17
- Microsystems, S. (1999). *Programming in Java advanced imaging*. Sun Microsystems, Inc. Business.
- Miranda, J. I. (2006). *Processamento de Imagens Digitais: Prática Usando Java*. Embrapa, 1ª edição.
- Mokhtarian, F. e Abbasi, S. (2004). Matching shapes with self-intersections: Application to leaf classification. *IEEE Transactions on Image Processing*, 13(5):653–661. 5
- Montgomery, D. C. e Runger, G. C. (2010). *Applied Statistics and Probability for Engineers*. Wiley, 5ª edição. 36
- Nam, Y.; Hwang, E. e Kim, D. (2008). A similarity-based leaf image retrieval scheme: Joining shape and venation features. *Computer Vision and Image Understanding*, 110(2):245–259. 5

- Nazaré-Jr, A. C.; Menotti, D.; Neves, J. M. R. e Sediyaama, T. (2010). Automatic detection of the damaged leaf area in digital images of soybean. In *IEEE International Conference on Systems, Signals and Image Processing (IWSSIP)*, pp. 499–503. [2](#), [3](#), [9](#), [10](#), [40](#), [41](#)
- Nixon, M. e Aguado, A. (2008). *Feature Extraction & Image Processing*. Elsevier, 2ª edição. [17](#), [20](#)
- Ohta, Y.-I.; Kanade, T. e Sakai, T. (1989). Color information for region segmentation. *Computer Graphics and Image Processing*, 13(3):222–241. [7](#)
- Osowski, S. e Nghia, D. D. (2002). Fourier and wavelet descriptors for shape recognition using neural networks - a comparative study. In *Pattern Recognition*, volume 35, pp. 1949–1957. [3](#), [16](#), [34](#)
- Otsu, N. (1979). A threshold selection method from gray-level histograms. *IEEE Transactions on Systems, Man and Cybernetics*, 9(1):62–66. [9](#)
- Papa, J. P.; de Albuquerque, V. H. C.; Falcão, A. X. e Tavares, J. M. R. S. (2012). Efficient supervised optimum-path forest classification for large datasets. *Pattern Recognition*, 45(1):512–520. [41](#)
- Picanço, M. C. e Guedes, R. N. C. (1999). Manejo integrado de pragas no brasil: situação atual, problemas e perspectivas. *Ação Ambiental*, 2(4):23–26. [1](#)
- Rezende, S. O. (2005). *Sistemas Inteligentes: Fundamentos e Aplicações*. Manole, 1ª edição. [21](#)
- Souza, T. L. G.; de Almeida, S. S. e Menotti, D. (2011a). Caracterização automática de agentes causadores de danos em folíolos de soja. In *WUW-SIBGRABI 2011*, pp. 1–6, Maceió. [8](#), [40](#)
- Souza, T. L. G.; Mapa, E. S.; dos Santos, K. e Menotti, D. (2011b). Application of complex networks for automatic classification of damaging agents in soybean leaflets. In *IEEE International Conference of Image Processing (ICIP)*, pp. 1089–1092. [3](#), [10](#), [40](#)
- Souza, T. L. G.; Menotti, D.; Neves, J. M. R. e Sediyaama, T. (2010). Desenvolvimento de uma interface online de avaliação manual em rumo a um método automático de caracterização dos agentes causadores de lesões em folíolos de cultivares de soja. In *Workshop of Undergraduate Works - Brazilian Symposium on Computer Graphics, Image Processing and Computer Vision*, pp. 1–5, Gramado-RS, Brazil. [1](#), [8](#), [25](#)
- Styrsky, J. D.; Kaplan, I. e Eubanks, M. D. (2005). Plant trichomes indirectly enhance tritrophic interactions involving a generalist predator, the red imported fire ant. *Biological Control*, 35(3):375–384. [1](#)

- Theodoridis, S. e Koutroumbas, K. (2008). *Pattern Recognition*. Elsevier, 4^a edição. [22](#)
- Wang, X.-F.; Huang, D.-S.; Du, J.-X.; Xu, H. e Heutte, L. (2008). Classification of plant leaf images with complicated background. *Applied Mathematics and Computation*, 205(2):916–926. [6](#)
- Watts, D. J. e Strogatz, S. H. (1998). Collective dynamics of 'small-world' networks. *Nature*, 393(6684):440–442. [11](#)
- Zahn, C. e Roskies, R. (1972). Fourier descriptors for plane closed curves. *IEEE Transactions on Computers*, 21(3):269–281. [3](#), [5](#)
- Zhang, M. e Meng, Q. (2011). Automatic citrus canker detection from leaf images captured in field. *Pattern Recognition Letters*, 32(15):2036–2046. [6](#)
- Zhenjiang, M. (2000). Zernike moment-based image shape analysis and its application. In *Pattern Recognition Lett.* 21, pp. 169–177. [3](#), [21](#)